生物统计和生物信息引论

Lecture 1

生物统计中的数据类型

王健桥
jianqw@mail.tsinghua.edu.cn

为什么是我讲这门课?

课程信息

- 上课时间：每周二19:20-21:45
- 上课地点：建华楼A201
- 联系方式：
  - 邮箱： jianqw@mail.tsinghua.edu.cn
  - 办公室：吕大龙楼815
- 前置课程：概率论、统计推断、线性回归
- 助教：
  - 刘睿，邮箱：liurui25@mails.tsinghua.edu.cn



群聊：生物统计和生物信息引论



该二维码7天内(3月6日前)有效，重新进入将更新

考核方式

- 出勤10%
- 作业25%
  - 约2周一次，以PDF格式提交至网络学堂
  - Rmarkdown, Quarto, Jupyter Notebook, …
- 期中30%
- 期末35%

Software, AI tools and Policy

- Software: R, Python, Git + GitHub
- AI tools for learning are encouraged (use properly)
  - OpenAI Codex
  - Claude Code
  - Models: Kimi, MiniMax, DeepSeek..
- AI use policy
  - AI tools may be used as learning aids, but you must fully understand, verify, and be able to explain any work you submit.
  - All homework and project work must be completed independently; any form of unauthorized collaboration constitutes a violation of academic integrity.

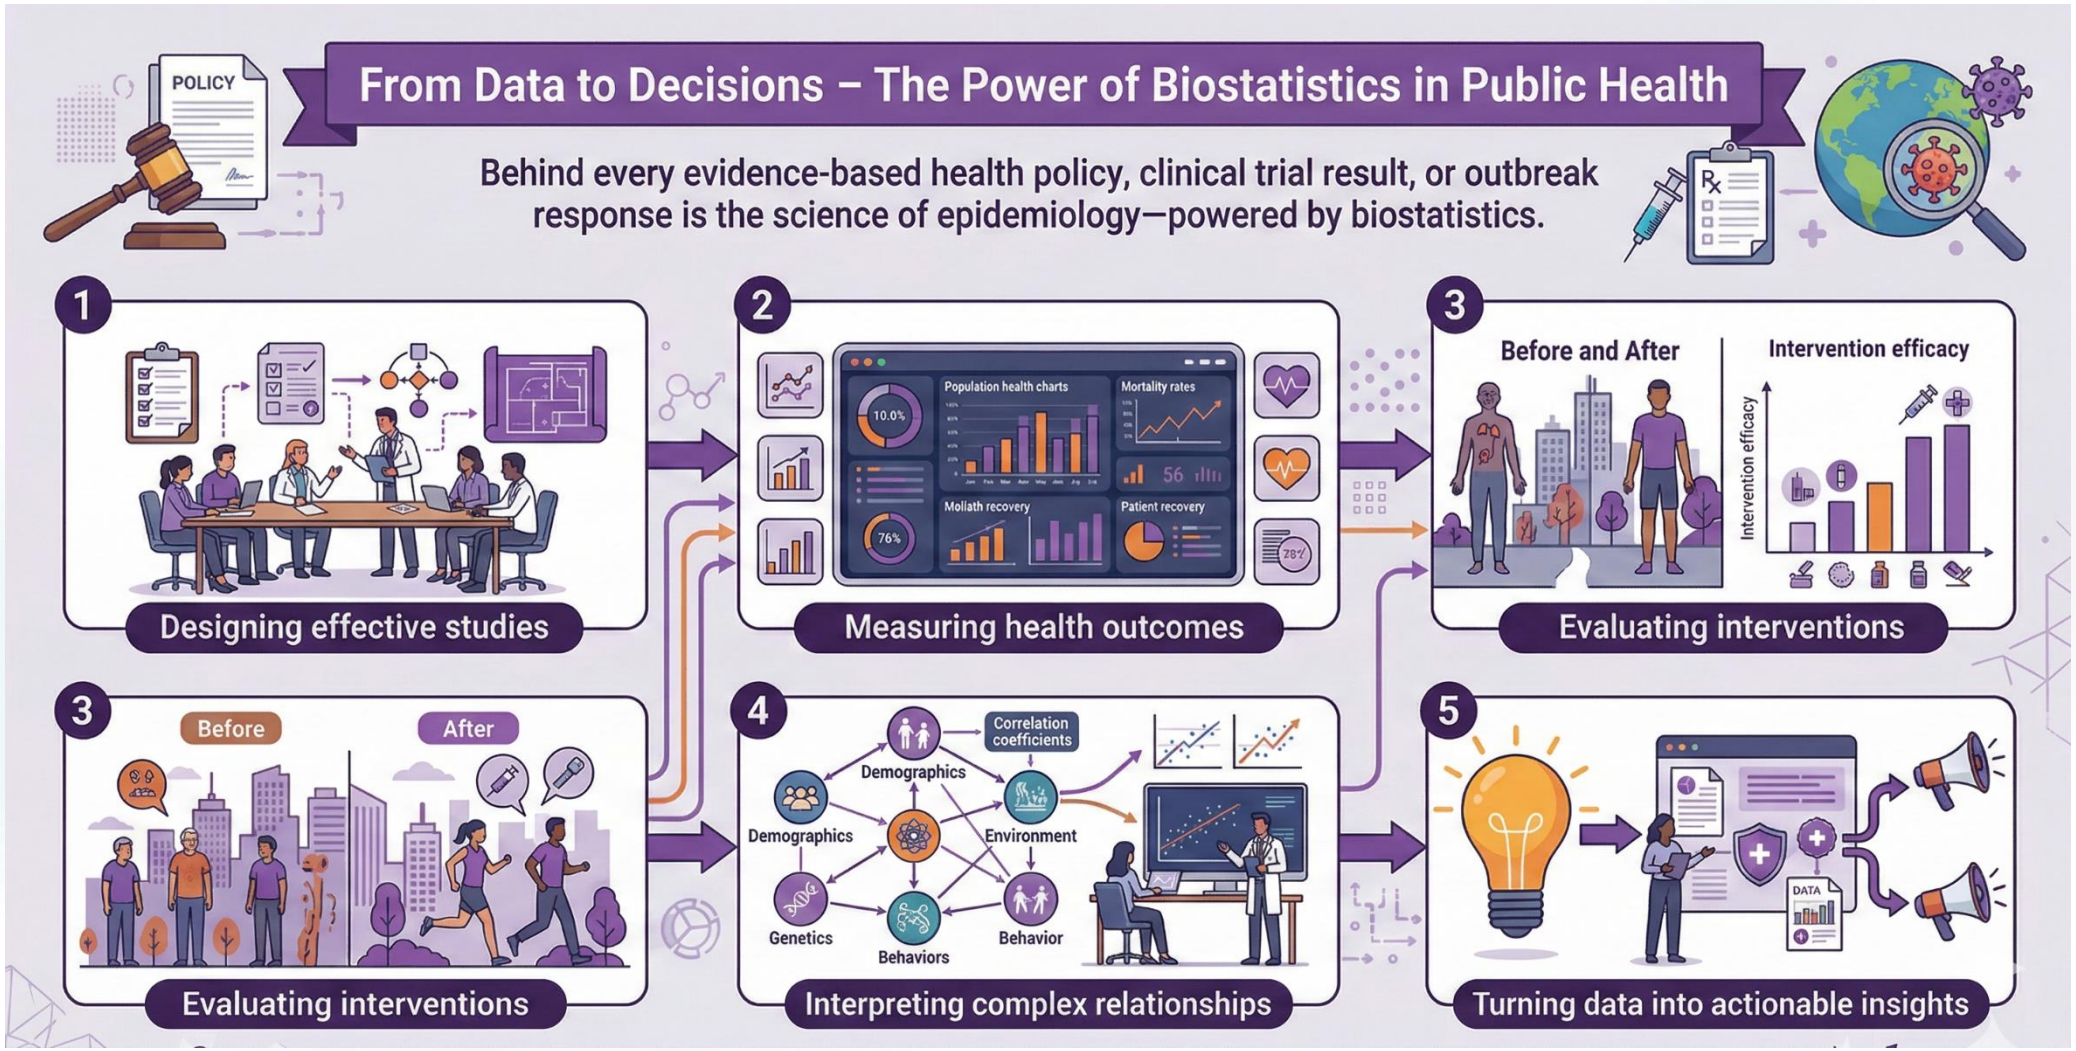
What is Biostatistics?

- Statistics applied to biological problems is called **biostatistics**.
- Using the tools of statistics, biostatisticians help answer pressing research questions in medicine, biology and public health, such as whether a new drug works, what causes cancer and other diseases, and how long a person with a certain illness is likely to survive.

--https://www.biostat.washington.edu/about/biostatististics

Role of Biostatistics in Public Health

- Address a public health question
- Conduct a study and collect data
  - Experimental study, observational study
- Describe the data/exploratory data analysis
- Assess the strength of evidence of a hypothesis, i.e., make inference
- Recommend interventions or preventive programs
  - Change of personal behavior, or regulation program in the public domain



Credit: Nonbanana

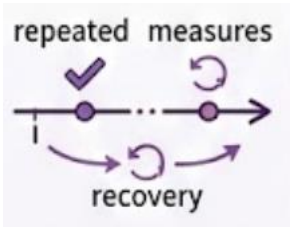
清華大學 统计与数据科学系
Department of Statistics and Data Science, Tsinghua University

Why Biostatistics?

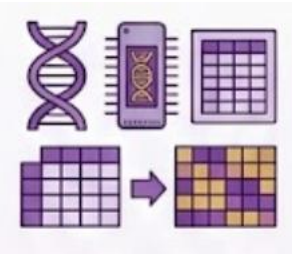
- 传统统计中的数据类型
  - 独立同分布的样本



- 生物统计中的数据类型
  - 横断面数据（Cross-sectional）
  - 纵向数据（Longitudinal）
  - 生存数据（Time-to-event）
  - 现代生物数据







- 数据是真实世界的投影
- 不同研究问题 → 不同数据结构 → 不同统计方法

统计数据的基本维度

- 个体（unit）
  - 病人、动物、细胞、蛋白质、脑区、设备佩戴者
  - 你关心的客体
- 变量（covariate）
  - 基因、生理指标、环境因素
  - 考虑事情的维度
- 时间（time）
  - 是否只测量一次？是否反复测量？是否持续测量？
- 统计数据的基本维度：个体×变量×时间
- 什么是独立同分布的数据？

时间维度如何决定数据结构

- 传统统计问题中，数据通常被视为n个独立个体×每个个体一次观测，存在i.i.d.结构
- 但在实际问题中，同一个个体可能会被反复观测，或在不同时间进入研究；不同个体之间也不一定独立
- 例：
  - 一次观测：横断面数据
  - 多次观测：纵向数据
  - 关注事件发生时间：生存数据
  - 个体相关性：蛋白质、基因数据
  - …

横断面数据（Cross-sectional Data）

- 每个个体只在一个时间点被观测一次
- 最常见的数据类型，如基因型数据、一次性体检指标、问卷调查等
- 研究目标：总体分布（如均值、方差、分布形态、群体差异等）；
  关联关系（如BMI与血压关系等）

病例（一）

姓　名		住院号	210765	孕周	29+2	年龄	33岁
孕前体重	61kg	身　高	165cm	BMI	22.4kg/m²	体重增加	9kg
OGTT	4.12—10.46—8.42mmol/L（25周）					HbAlc	5.5%
备注	门诊给予饮食及运动指导，监测血糖。 空腹血糖：5.3-5.8mmol/L， 餐前血糖：4.8-5.8mmol/L， 餐后血糖：5.3-8.9mmol/L。 近一月体重减轻1.5Kg。						
入院诊断	1. 妊娠期糖尿病 2. 孕$_2$产$_0$孕29+2周LOA单活胎						



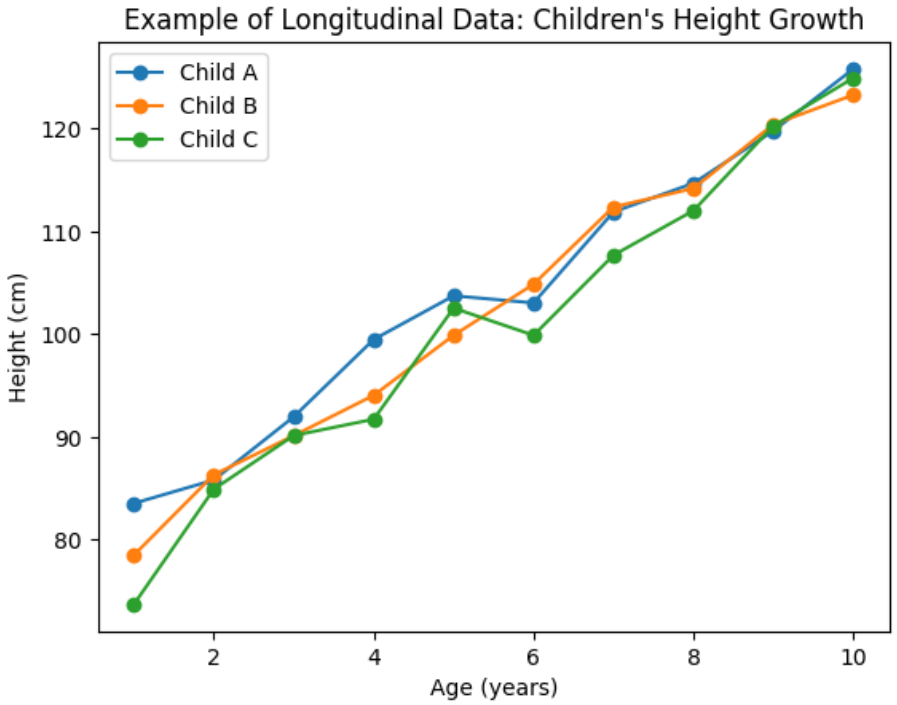
横断面数据（Cross-sectional Data）

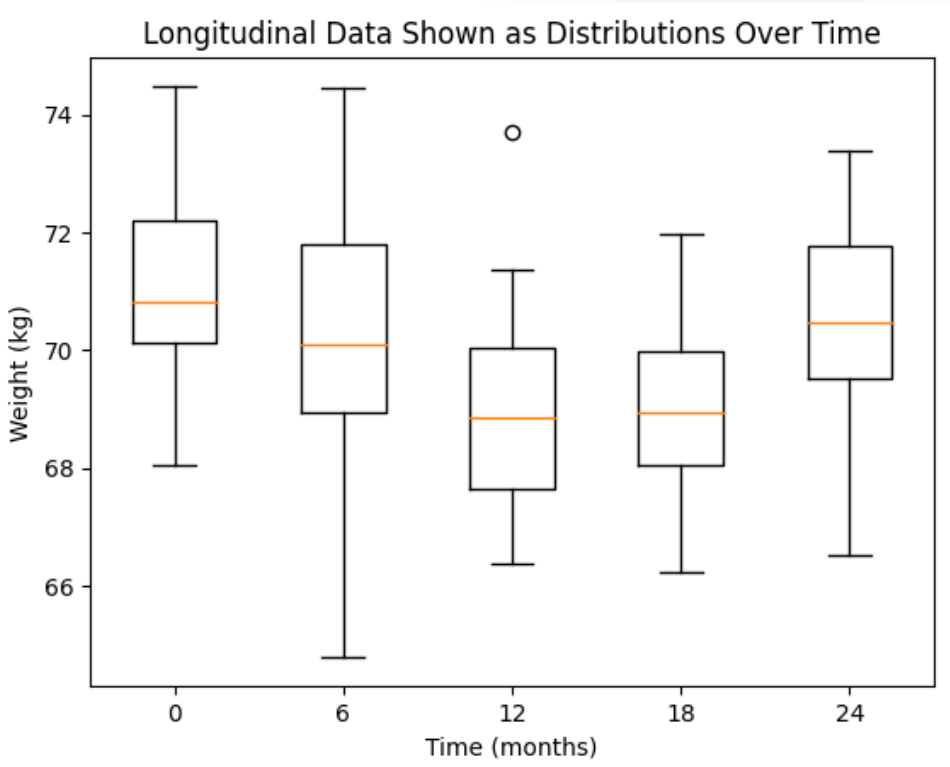
- 例：体检指标数据

患者ID	年龄	身高	体重	性别	是否吸烟
1	34	172	68	1	0
2	58	165	72	0	0
3	45	178	85	1	1
4	29	160	54	0	0
5	63	170	78	1	1
6	51	162	70	0	0
7	39	180	90	1	0

纵向数据（Longitudinal Data）

- 同一个体在多个时间点被重复测量（在数据中多次出现）
- 研究目标：刻画随时间的变化轨迹（如某种生理指标变化、儿童生长曲线等）；个体异质性和时间异质性





纵向数据（Longitudinal Data）

- 例：随访生理指标

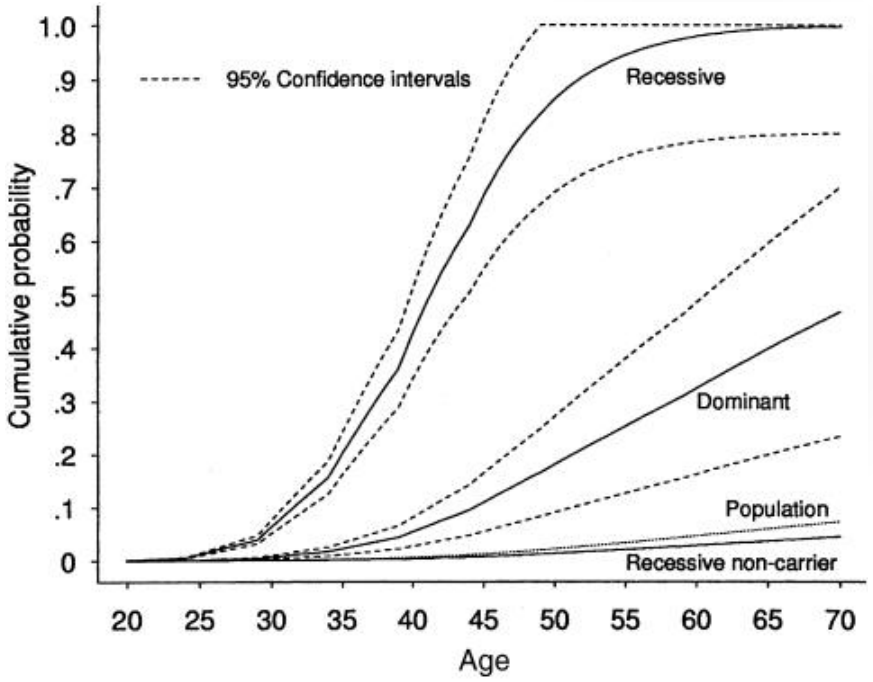
患者ID	时间	年龄	体重	是否吸烟	血压
1	0	45	72	1	130/90
1	6	46	70	1	135/88
1	12	46	69	0	125/86
2	0	52	80	0	145/80
2	6	52	78	0	140/82
2	12	53	76	1	145/88

纵向数据（Longitudinal Data）

- 区别以下两种测量
  - 同一时间测3次：数据冗余，本质上是1个数据点
  - 不同时间测3次：3个数据点，但不等价于3个独立个体
- 数据分析挑战：时间依赖；同一个体的重复观测存在相关性

生存数据（Time-to-event Data）

- 事件（如死亡、复发、感染、设备失效等）什么时候发生
- 研究目标：事件发生时间的分布
- 生存曲线：$S(t) = \Pr(T > t)$
  - $S(0) = 1$
  - $\lim_{t\to\infty} S(t) = 0$
  - 如果T是连续的，则有 $S(t) = 1 - F(t)$
- 累计概率曲线：$F(t) = \Pr(T \le t)$

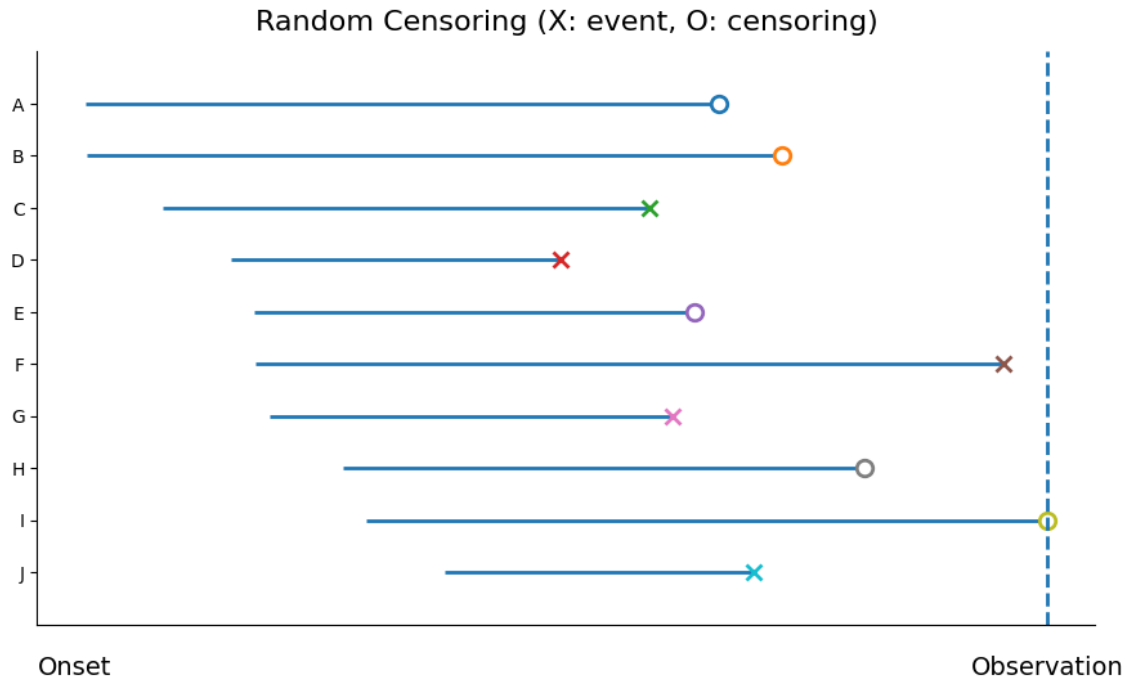


- 如果能观测到所有个体的结果，相当于横断面数据（普通的连续型结果数据）

致病基因对发病率的影响

生存数据（Time-to-event Data）

- 关键概念：删失（censor）
  - 个体由于某种原因无法被观测到
  - 只知道事件时间 大于 删失时间
- 数据存在缺失
- 数据分析挑战：删失



生存数据（Time-to-event Data）

- 例：带协变量的生存数据　事件：1=发生，0=删失

患者ID	事件时间	事件	年龄	性别	是否吸烟
1	10	1	72	1	1
2	22	0	70	1	1
3	15	1	69	0	0
4	30	1	80	0	0
5	8	0	78	0	0
6	12	1	76	1	0

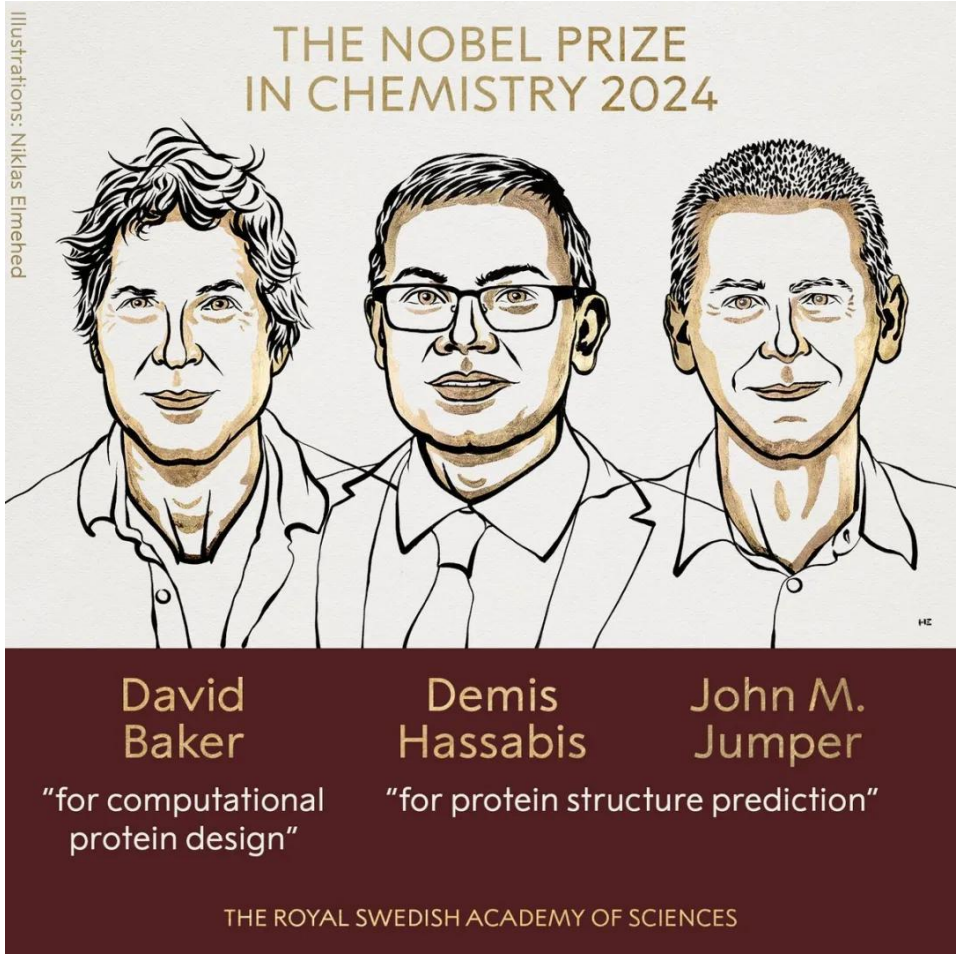
- 只保留未删失样本会造成选择偏差
- 将删失机制纳入建模或加权

三种数据类型的区别和联系

	Cross-sectional Data	Longitudinal Data	Time-to-event Data
基本数据结构	每个个体观测一次	每个个体多次测量	每个个体的事件发生时间
时间维度	无	多时间点	事件发生时间是outcome
时间的作用	无	作为协变量参与建模	作为核心目标变量
特点	最常见的数据类型	存在时间依赖	存在删失
核心统计目标	分布、关联	变化轨迹	事件发生时间分布
样本量理解	样本总数	样本总数×测量次数	样本总数
应用例子	单次体检数据	随访血压	生存/复发时间
关键词	状态	变化	何时发生

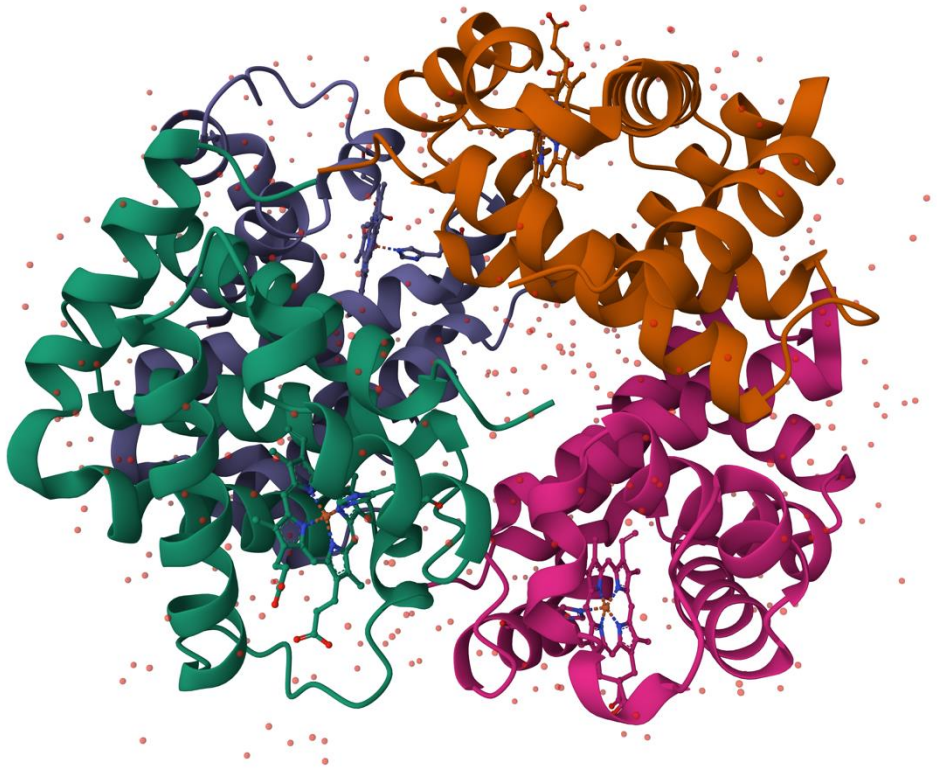
蛋白质结构数据

- 2024年诺贝尔化学奖：以AlphaFold为代表的AI技术在蛋白质结构预测与蛋白质计算设计中的革命性影响
- AI+Science新纪元
- AlphaFold：给定氨基酸序列，预测其在天然状态下的三维结构
- 核心思想：通过已知蛋白质结构数据，学习氨基酸序列中蕴含的进化约束，并将其转化为几何约束，从而直接预测三维结构



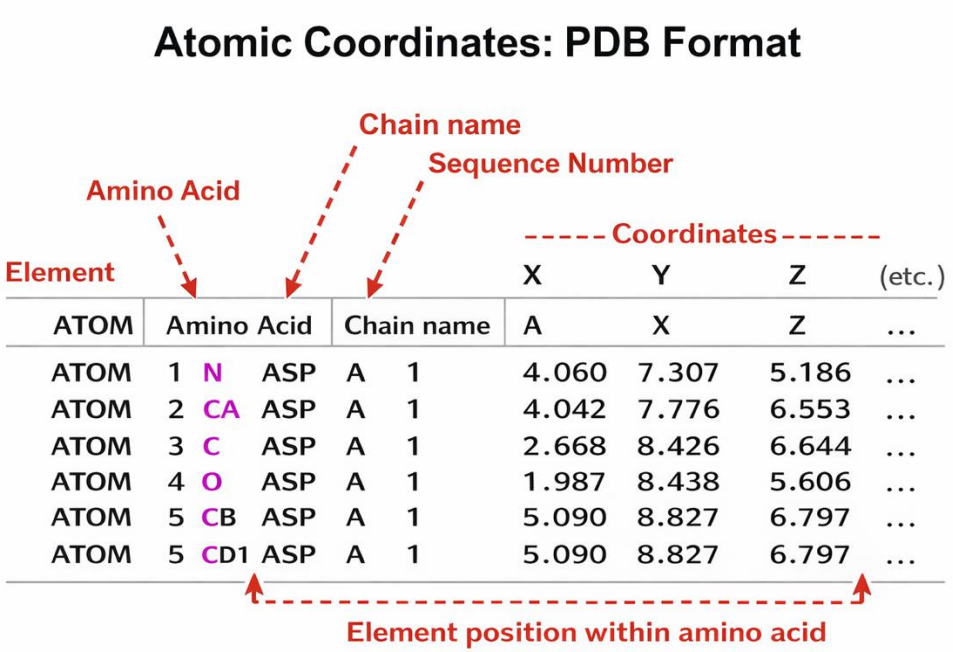
蛋白质的构成

- 一级结构：氨基酸线性序列
  - 共有20种基本氨基酸
  - 由DNA编码
  - 形成多肽
- 二级结构：螺旋、折叠
- 三级结构：多肽链三维折叠
- 四级结构：多条多肽链组成复合物
- 例：血红蛋白的可视化
  - 含有四条链，周边的点为水分子



蛋白质数据：以Protein Data Bank为例

- PDB存储的主要是原子级别的3D坐标
- 主要数据单元：原子（Atom）
- 多个原子组成一个氨基酸（Amino Acid）
  - ASP：天冬氨酸
- 多个氨基酸组成一条链（Chain）
- 原子所在的坐标（X、Y、Z）

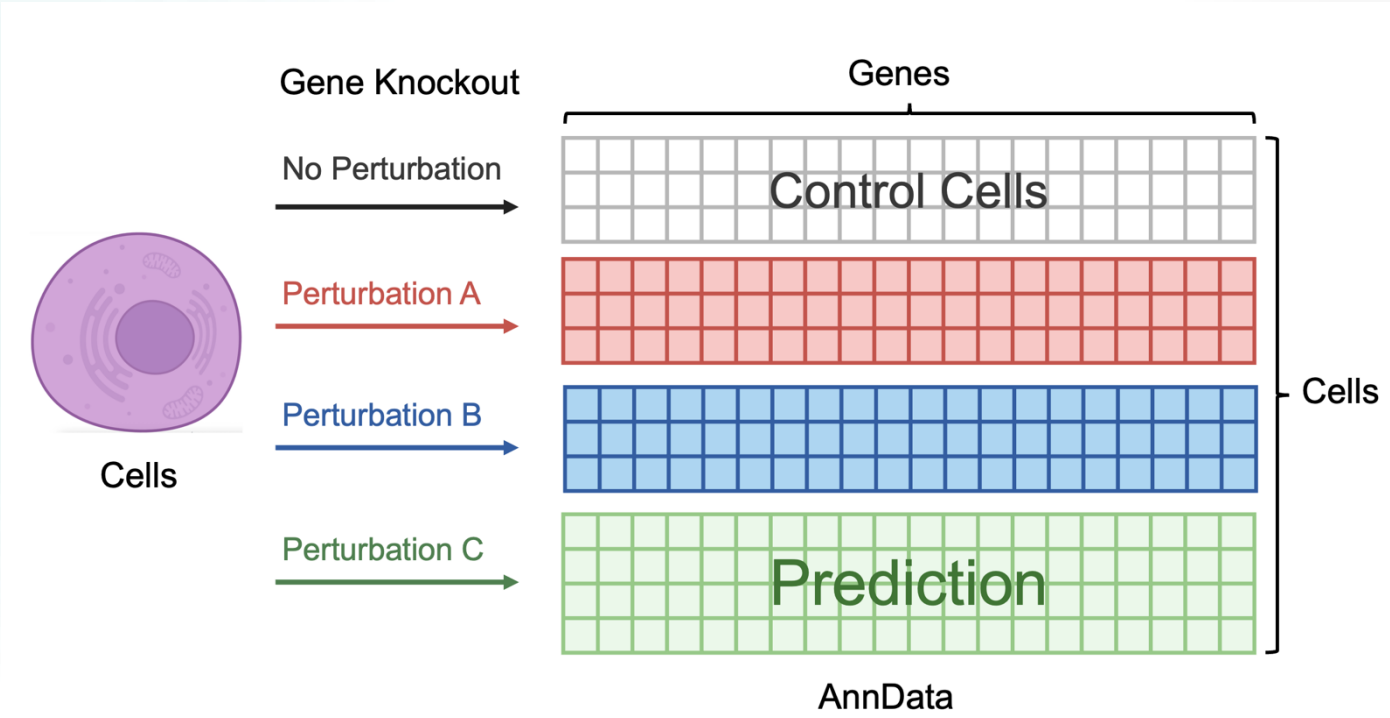


蛋白质数据：以Protein Data Bank为例

- 数据分析挑战
  - 1. 数据单元不匹配：数据是原子级的，但是科学问题通常在更高级
    - 原子→氨基酸→多肽→蛋白质
  - 2. 蛋白质结构的旋转不变性
    - 坐标整体平移旋转后生物意义不变
  - 3. 原子坐标间的结构约束（空间相关性）…

单细胞数据（Single Cell Data）

- 每行为一个细胞，每列为一个基因，数据单元：某类细胞的某个基因
- 每个小格子代表该单元里的表达量
- Perturbation（扰动、干预）：如敲除某个基因
- 用在其他类型扰动（A、B）下观测到的单细胞表达分布去预测未观测扰动（C）下的表达分布



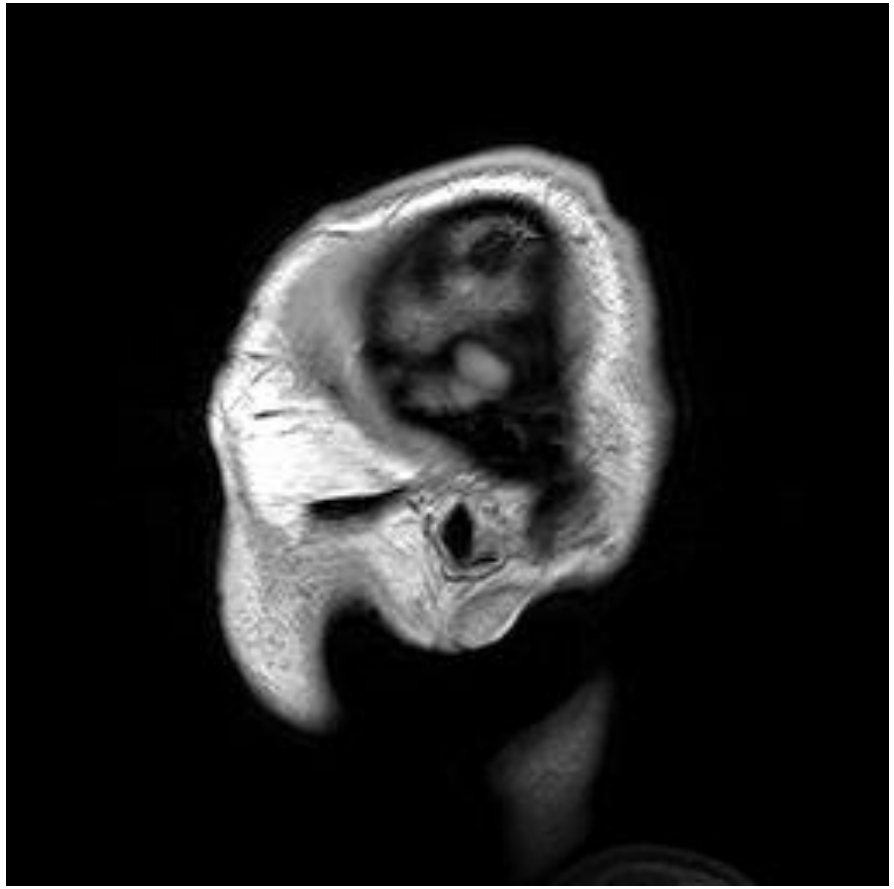
单细胞数据的稀疏性和零膨胀

- 稀疏性（sparsity）：真的不表达
  - 在单细胞层面，每个细胞真实表达的基因只占全部基因的一小部分。
  - 直观：细胞只需要表达与自身功能相关的一小部分基因。
- 零膨胀（zero inflation）：表达了但被测成0
  - 在测序过程中，很多表达了的基因，因技术原因“没测到”，于是多出了很多额外的0。
  - 直观：测序过程很长，中间任何一步（逆转录、扩增等）出现问题都会导致0的出现。同时，测序中捕获效率低也会导致没进入测序数据。
- 考试中很多人得了0分，一部分人是没来考试（稀疏性），另一部分人是来了考试但不会做（零膨胀）

- 数据分析困难：如何区分稀疏性和零膨胀？ （Measurement error）

核磁共振成像（Magnetic Resonance Imaging）

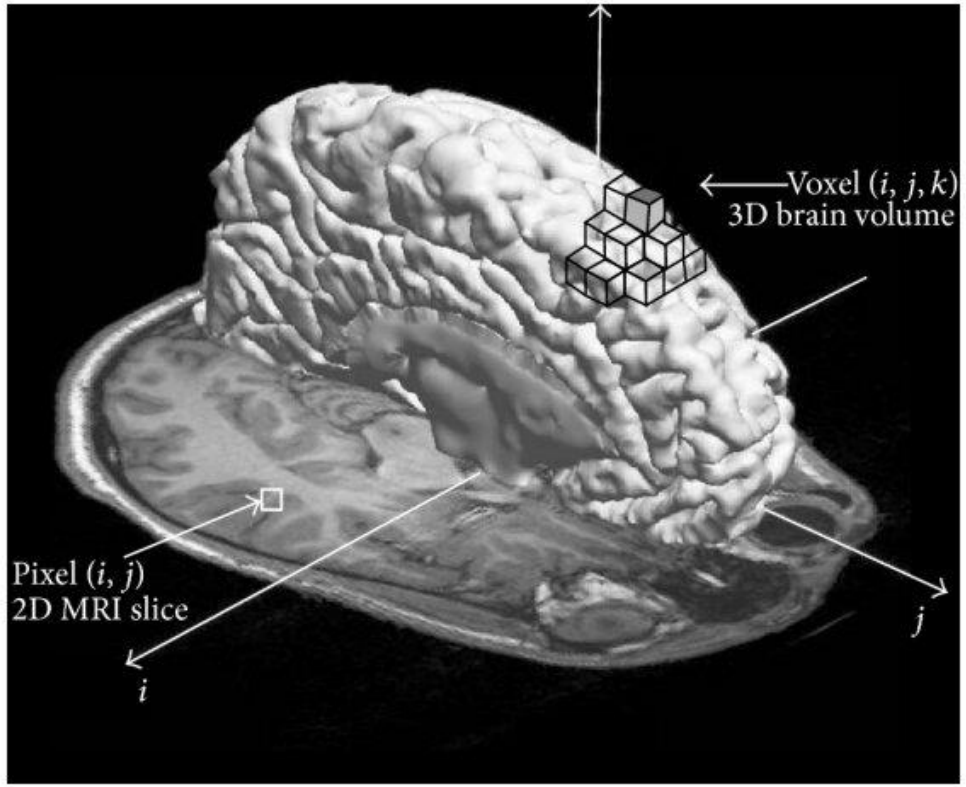
- 基于核磁共振原理、用于影像诊断学的医学成像技术
- 核磁共振：在强磁场中，生物体中分子的原子核（主要是氢原子）受到特定频率的射频电磁波照射，发生能级跃迁并吸收能量，产生共振。射频脉冲停止，原子核回到低能态，释放能量（信号），从而造影



- 能级跃迁：原子核的能量并不是连续的，只能从某个值“跃迁”到某个值，采用特定频率磁场可以只让某类原子核跃迁

核磁共振成像（Magnetic Resonance Imaging）

- 主要数据单元：体素
- 定义：体素是三维空间的最小单元，对应于图像中一个小立方体的空间区域，类似二维图像中的像素
- 每个体素具有一个强度值（signal intensity），反映该体素内信号强度
- 每个体素在三维空间中都有固定坐标，通常用 (x, y, z) 表示
- 数据格式：坐标×强度



核磁共振成像（Magnetic Resonance Imaging）

- 数据分析挑战
  - 1. 高维性
    - 典型的脑MRI扫描可能包含上百万个体素，导致数据维度极高
    - 高维数据容易出现“维度灾难”，使得传统统计方法难以直接使用
  - 2. 空间相关性
    - 相邻体素之间通常高度相关，因为组织结构连续，信号平滑
    - i.i.d. 假设被违背
  - 3. 噪声与个体差异
    - 常用高斯噪声假设可能不成立
    - 个体脑结构差异大，需要对齐或标准化处理
  - …

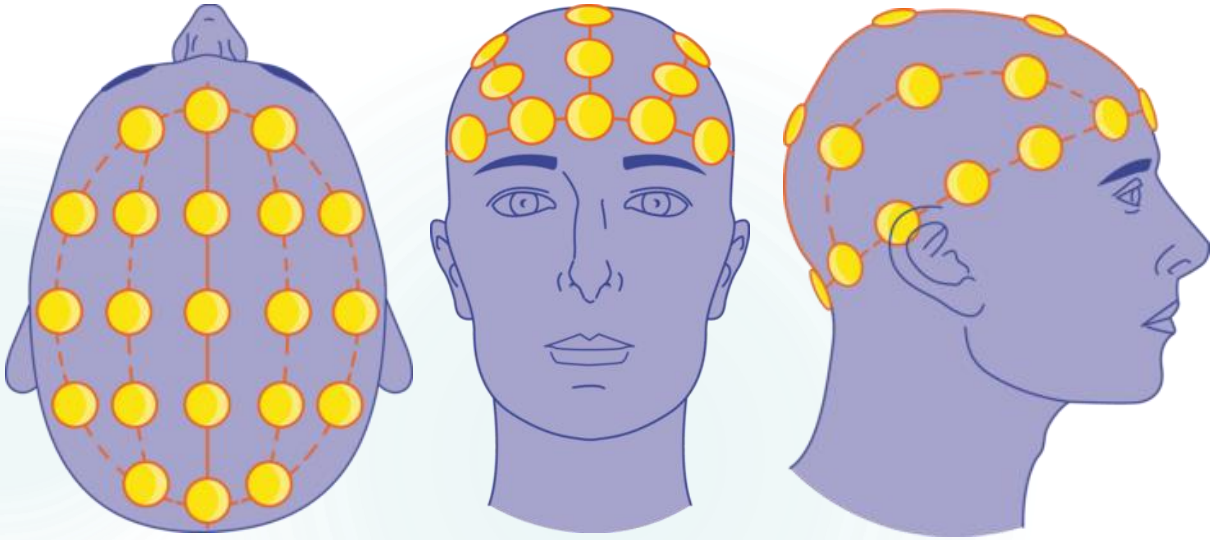
脑电图（electroencephalography）

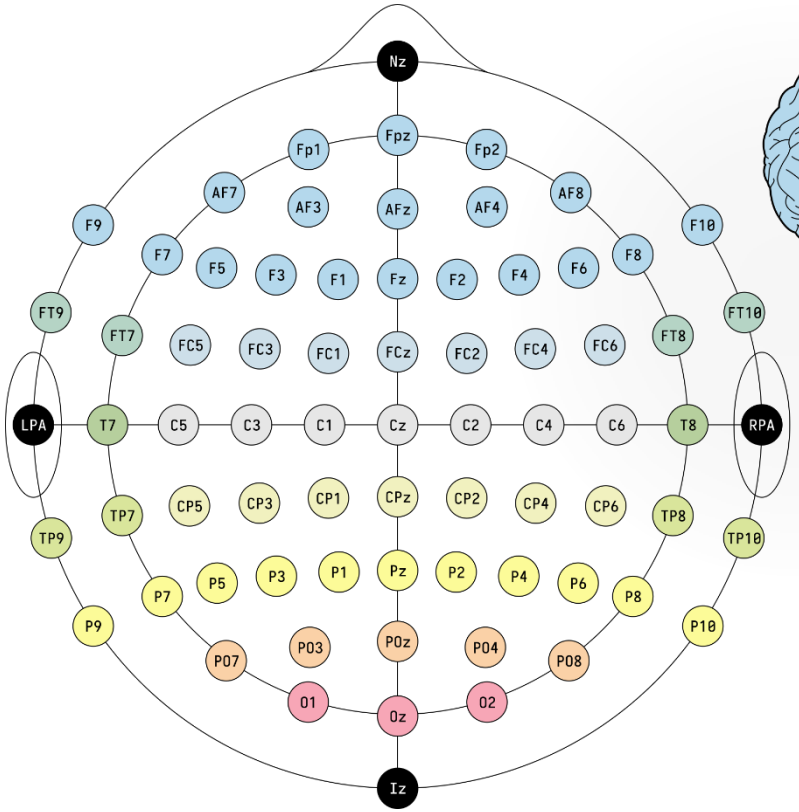
- 脑电图（EEG）是用置于头皮、脑表面或脑组织内的电极检测人体脑部自身产生的微弱电位变化，加以放大并记录下来而得到曲线图的技术。
- 脑电图检测到的生物信号与皮层锥体神经元的突触后电位有关，因此可以借助脑电图检测异常放电。
- 不同的脑部活动会产生不同生物电强度

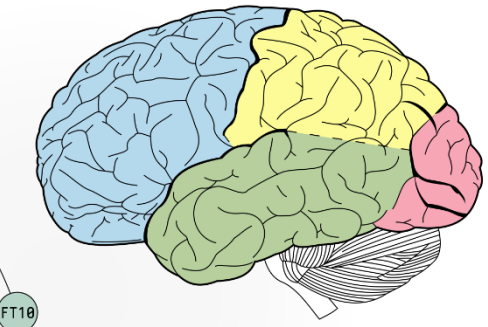


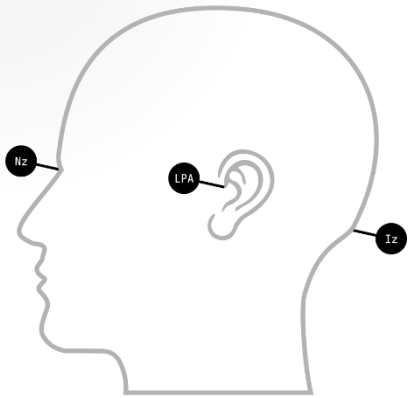
脑电图（electroencephalography）

- 数据收集方式：在头皮上放置电极进行电信号采集









脑电图（electroencephalography）

- 主要数据单元：电极（通道）
- 每个电极在每个采样时间会采集电压值，从而绘制出脑电曲线
- 数据格式：通道×时间×强度



脑电图（electroencephalography）

- 数据分析挑战
  - 1. 信噪比低
    - 脑电信号微弱，易受眼电、肌电等噪声干扰
  - 2. 空间分辨率有限
    - 电信号相互重叠，定位不精确
  - 3. 高维小样本
    - 通道×时间×强度，维度高，被试数量有限
  - 4. 时间相关与非平稳
    - 脑电信号随时间变化，前后时间信号强相关
    - 存在非平稳性
  - …

EEG 以及 MRI的应用

- EEG：
  - 癫痫诊断
  - 睡眠医学 （Dream）
  - 脑功能状态
  - 认知科学
  - 脑机接口

- MRI ：
  - 结构MRI: 组织结构和解剖信息 (脑萎缩 发育异常)
  - 功能MRI :血氧水平变化 (功能和脑区活跃程度)

可穿戴设备（wearable devices）

- 心率、步数、睡眠数据…
- 和传统数据的区别和特点是什么？ （Homework）

相关（Association）vs 因果（Causality）

- 吃巧克力能帮助中国赢得诺贝尔奖吗?
  - N Engl J Med 2012; 367:1562-1564
- 相关不代表因果!

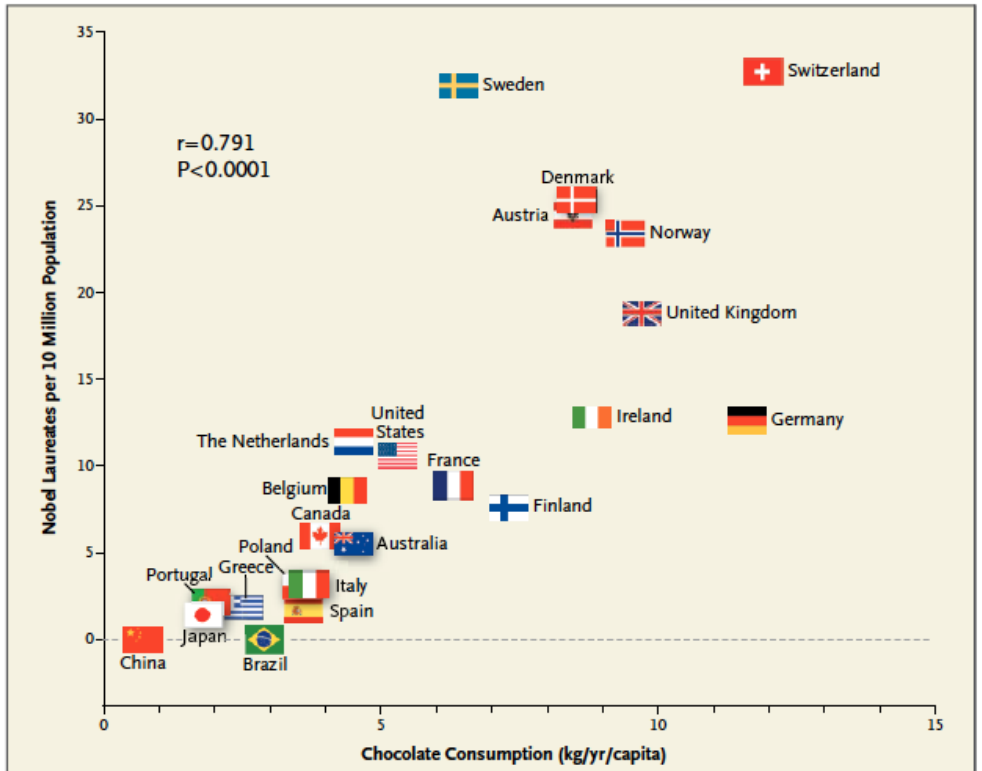


Figure 1. Correlation between Countries' Annual Per Capita Chocolate Consumption and the Number of Nobel Laureates per 10 Million Population.

因果推断与传统数据分析的区别

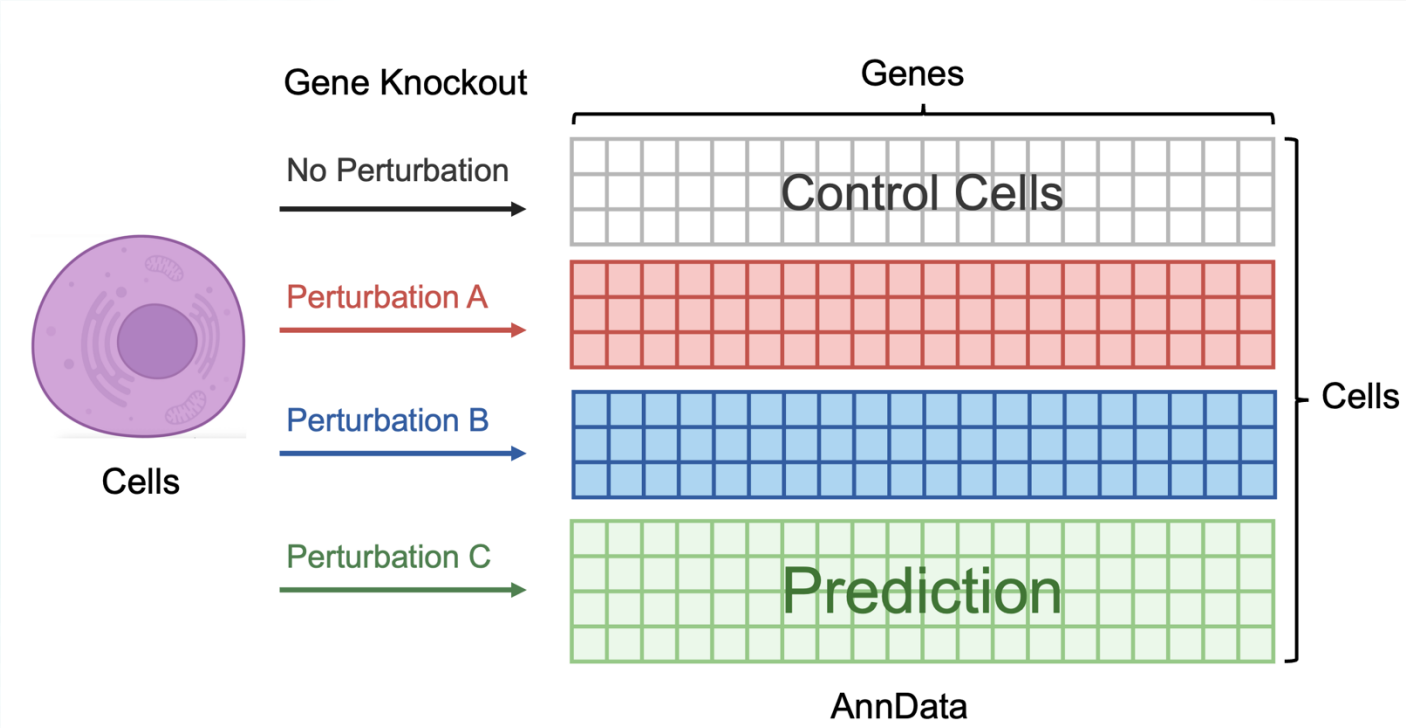
- 传统数据分析：
  - 描述模式
  - 预测结果
  - 常见：回归、聚类、PCA、预测模型…
- 但很多科学问题关注：如果我这样做，会发生什么？
- 因果推断中的两类变量：
  - 处理变量（Treatment，可被外界操控）如：是否吃药
  - 协变量（Covariate，自然存在的变量）如：性别、年龄
- 因果推断关心的问题：处理变量变化后对某个结果变量（Outcome）的影响

因果推断的基本概念

- 什么变量是处理变量?
- 区别下面两个问题:
  - 如果我的性别改变，会发生什么?
  - 如果我在简历中保持其他内容不变，仅更改自己的性别标记，会发生什么?
- 是否存在一个明确、可局部施加、且不破坏系统其余生成机制的干预

因果推断：以单细胞数据为例

- Treatment：Perturbation，如某个基因被敲除
- Outcome：高维表达向量



本课程路线图预览

生物统计和生物信息引论

统计推断基础回顾	约1讲
因果推断 试验设计与观察性研究	约2讲
横断面数据 Cross-sectional Data	约3讲
生存数据 Time-to-event Data	约2讲
纵向数据 Longitudinal Data	约1讲
现代生物数据 蛋白质、单细胞、脑电数据……	约3讲
现代统计方法 大规模统计推断、变量选择、FDR……	约3讲