生物统计和生物信息引论

Lecture 3

因果推断简介

王健桥
jianqw@mail.tsinghua.edu.cn

清華大學 统计与数据科学系
Department of Statistics and Data Science, Tsinghua University

Recall: Association vs Causality

- 吃巧克力能帮助中国赢得诺贝尔奖吗?
  - N Engl J Med 2012; 367:1562-1564
- 相关不代表因果!

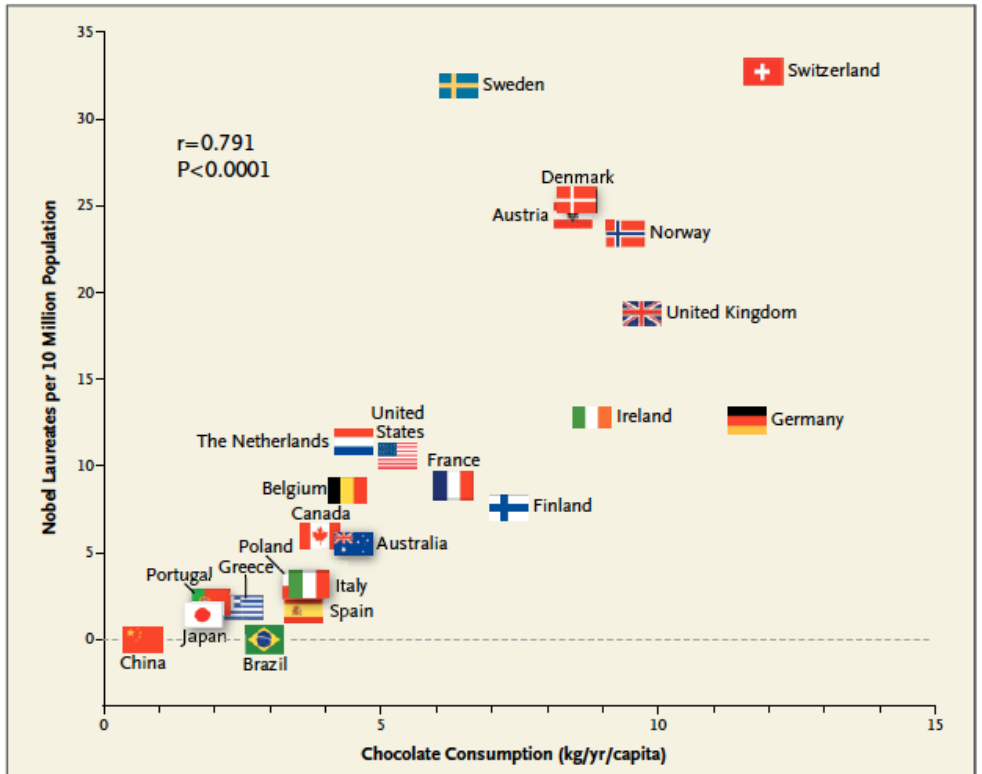
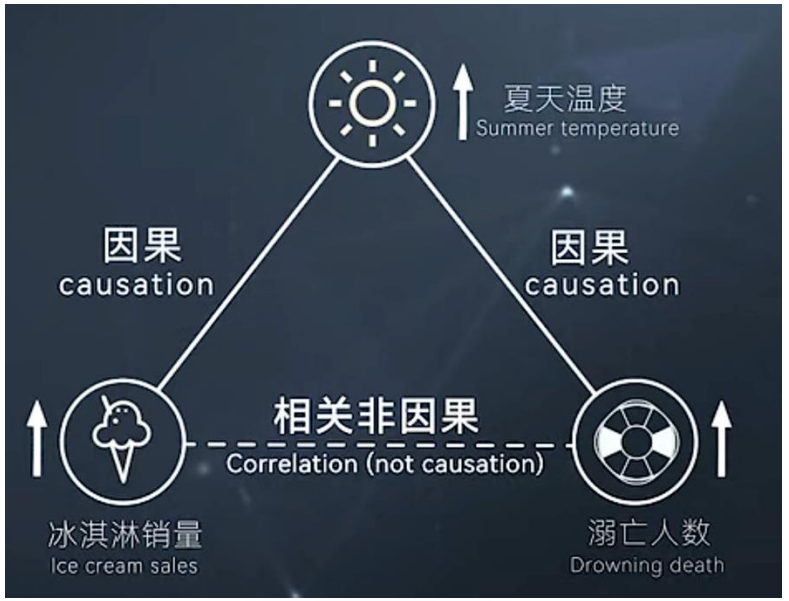


Figure 1. Correlation between Countries' Annual Per Capita Chocolate Consumption and the Number of Nobel Laureates per 10 Million Population.

Examples：为什么相关不等于因果?

- 现象：冰淇淋销量上升的同时发现溺水人数上升
  - 问题：冰淇淋是否导致溺水人数上升?
  - 真实原因：温度（既影响了冰淇淋人数上升，又影响了游泳人数，从而影响了溺水风险）
  - Confounder
- Discussion：服用维生素的人更健康



为什么我们关心因果?

- 现实研究中真正的问题:
  - 新药是否真的有效?
  - 更高教育是否能够提高收入?
  - 锻炼能否延长寿命?
  - 投放广告能否真的增加销售?
- 这些问题本质上都是因果问题
- 不是相关问题

因果推断与传统数据分析的区别

- 传统数据分析：
  - 描述模式
  - 预测结果
  - 常见：回归、聚类、PCA、预测模型…
  - 相关问题：吸烟是否与肺癌有关?
- 因果推断中的两类变量：
  - 处理变量（Treatment，可被外界操控）如：是否吃药
  - 协变量（Covariate，自然存在的变量）如：性别、年龄
  - 因果问题：吸烟是否导致肺癌?
- 因果推断关心的问题：处理变量变化后对某个结果变量（Outcome）的影响

因果推断与传统数据分析的区别

	传统统计	因果推断
目标	相关性/预测	干预效果
问题	Y是否与X相关	Y是否由X导致
例子	吸烟与肺癌是否相关?	禁烟能否减少肺癌?

Example：Aspirin-Headache

- 个体：我
- Treatment：服用Aspirin；$Y(\text{Aspirin})$
- Control：不服用Aspirin；$Y(\text{No Aspirin})$
- Causal Effect： $Y(\text{Aspirin}) - Y(\text{No Aspirin})$

1. Headache gone only with aspirin:
   $Y(\text{Aspirin}) = \text{No Headache}, Y(\text{No Aspirin}) = \text{Headache}$
2. No effect of aspirin, with a headache in both cases:
   $Y(\text{Aspirin}) = \text{Headache}, Y(\text{No Aspirin}) = \text{Headache}$
3. No effect of aspirin, with the headache gone in both cases:
   $Y(\text{Aspirin}) = \text{No Headache}, Y(\text{No Aspirin}) = \text{No Headache}$
4. Headache gone only without aspirin:
   $Y(\text{Aspirin}) = \text{Headache}, Y(\text{No Aspirin}) = \text{No Headache}$

因果推断的基本概念和核心目标

- 什么变量是处理变量?

- 处理变量（treatment）：$Z_i \in \{0,1\}$
- 结果变量（outcome）：$Y_i(1)$ and $Y_i(0)$

- 想回答的问题：如果同一个个体接受不同处理，结果会怎样?
  - 即对于个体i的处理效应：$\tau_i = E\{Y_i(1)\} - E\{Y_i(0)\}$
- 现实问题：只能观测到两个结果中的一个

因果推断的核心问题

- Population-level target estimand：$\tau = n^{-1}\sum_{i=1}^{n}\tau_i$
  - $\tau_i = E\{Y_i(1)\} - E\{Y_i(0)\}$
- 每个个体对应着2种结果（处理、对照），但只能观察到一个
- Counterfactual
- 这导致：因果效应无法直接观测

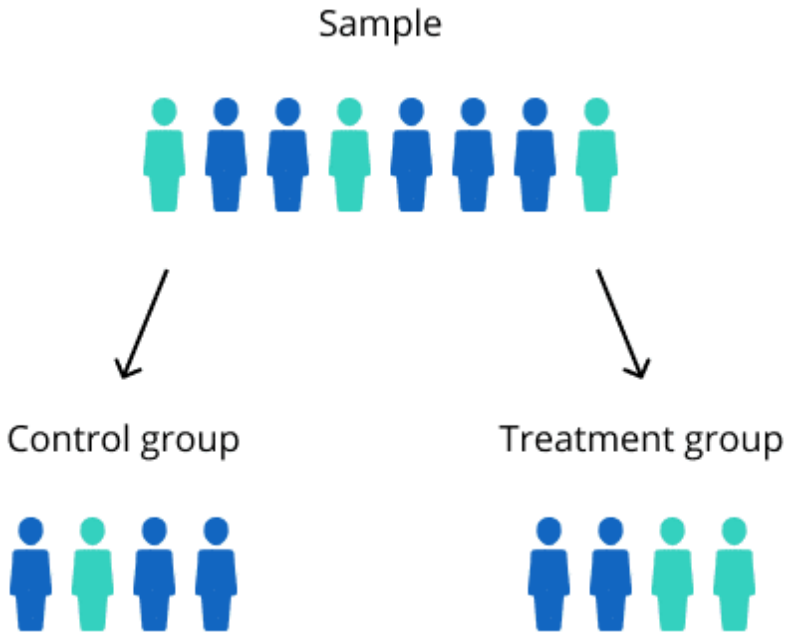
- 如何解决?
  - 随机化试验（Randomized Controlled Trial，RCT）
  - 观察性研究（Observational Study）+修正

随机化试验

清华大学统计与数据科学系
Department of Statistics and Data Science, Tsinghua University

什么是随机化试验?

- Randomized Controlled Trial, RCT
- 核心特征：处理对照随机分配 （控制变量）
- 因果推断中的金标准（gold standard）



RCT例子：新药试验

- 研究问题：某种新药是否能降低死亡率?
- 基本流程：
  - 定义研究对象
  - 随机分配处理对照
  - 实施干预并随访结果
  - 统计比较
- 关键：随机化

Potential Outcomes Framework

- 潜在结果
  - $Y_i(1)$：处理组观测到的结果
  - $Y_i(0)$：对照组观测到的结果
- Fundamental Problem：无法同时观测到$Y_i(1)$和$Y_i(0)$
- 处理对照分配：$Z_i \in \{0,1\}$
- 观测结果$Y_i = Z_i Y_i(1) + (1 - Z_i) Y_i(0)$

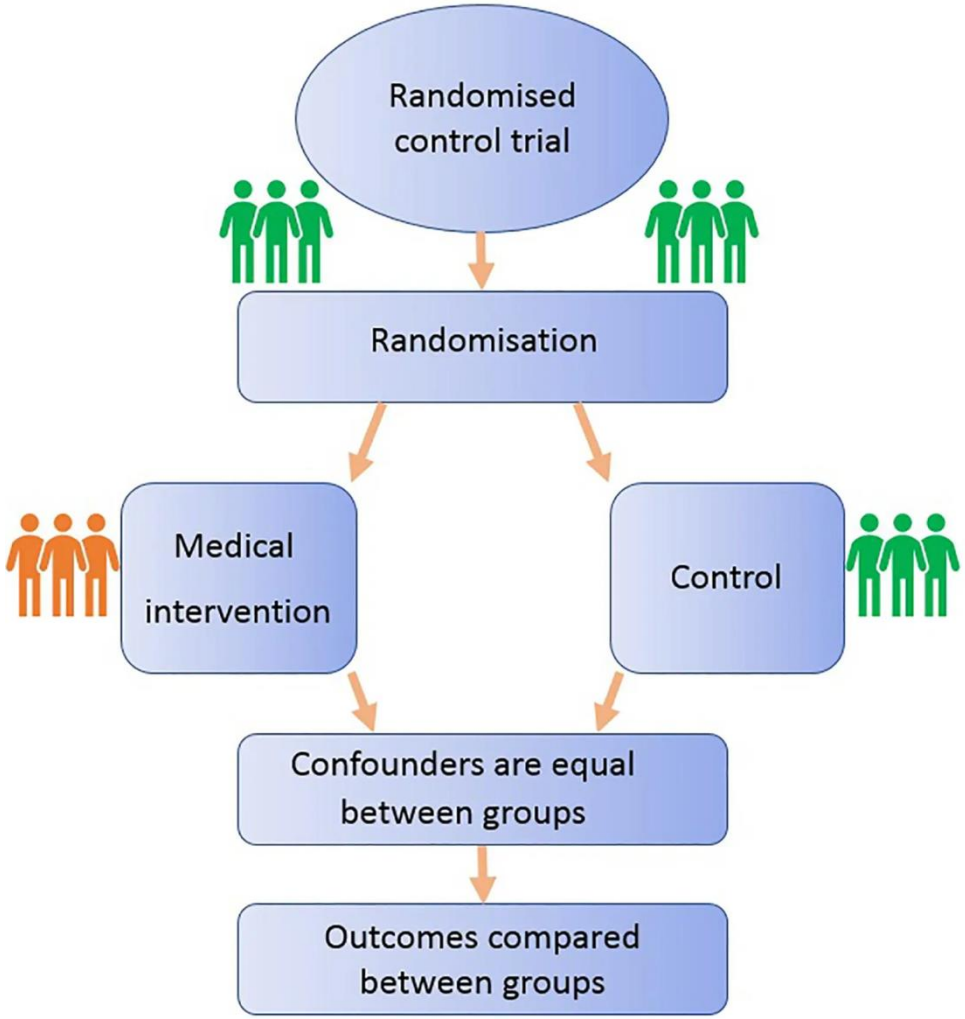
RCT中的因果效应估计

- 估计目标：平均因果效应
  - $\tau = n^{-1}\sum_{i=1}^{n} E\{Y_i(1) - Y_i(0)\} = \mu_1 - \mu_0$
  - $\mu_z = n^{-1}\sum_{i=1}^{n} E\{Y_i(1)\}$
  - 处理对照分配：$Z_i \in \{0,1\}$
  - $n_z = \sum_{i=1}^{n} I(Z_i = z)$
- 估计量：
  - $\hat{\tau} = \bar{Y}_1 - \bar{Y}_0$，其中$\bar{Y}_z = n_z^{-1}\sum_{i=1}^{n} I(Z_i = z)Y_i$，这是一个无偏估计

为什么随机化试验是有效的?

- 随机化保证了：$Z_i \perp \left(Y_i(1), Y_i(0)\right)$
- 从而使得$E\{Y_i \mid Z = z\} = E\{Y_i(z)\}$

- 随机化还能保证： $Z_i \perp U_i$ （U_i是可能的confounder）
- 使得confounder均匀分布
- 例子：新药试验
  - 除了是否采用新药，其他协变量（如年龄、性别、健康状况以及未观测到的其他变量）在处理组和对照组在期望意义上是一致的



Some Confounder Examples

- 教育对收入的影响
  - Treatment：是否接受大学教育
  - Outcome：未来收入
  - Confounder：家庭情况
- 学生干部经历对收入的影响
  - Treatment：是否担任学生干部
  - Outcome：毕业后的收入
  - Confounder：能力/性格外向程度…

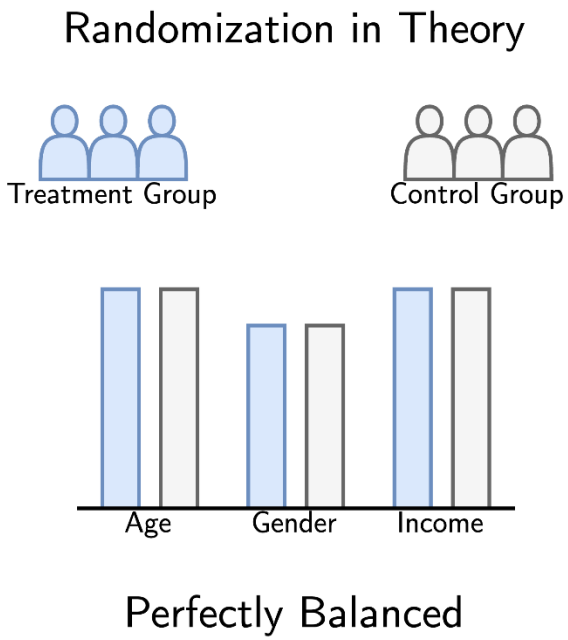
随机化试验的核心思想

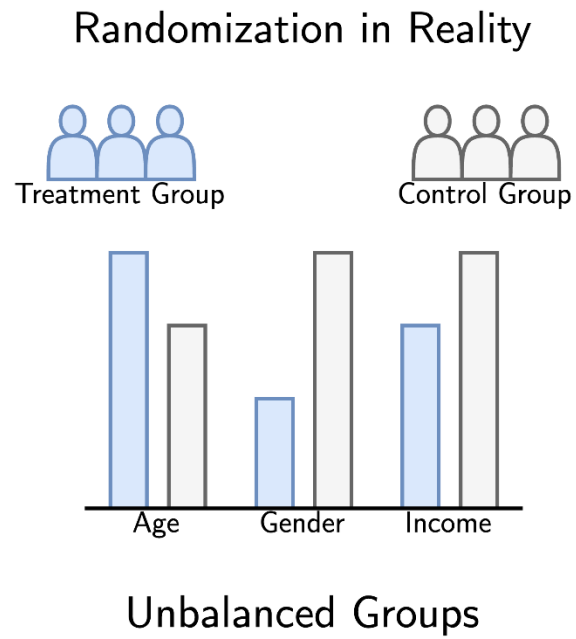
- 随机化的本质：打破confounder在处理组和对照组的差异
- 在非随机的情况下：
  - 富人更可能接受更好的教育
  - 严重/年龄大的患者更可能吃药
  - 健康意识更高的人更可能坚持运动
  - 经济条件更好的地区更容易推行某项新政策
  - …
- 这些都会造成偏差！

- 随机化能够使得治疗与个体特征独立，从而消除偏差。

有限样本中的随机化

- 虽然随机化在理论上能够保证协变量的完全平衡
- 但现实中可能会出现不平衡的情况
- 如：性别比例不同，年龄均值不同
- 解决方法：分层随机化
  - 按照性别、年龄等变量事先分层
  - Block what you can, randomize what you cannot. (George Box)
- 解决方法：重随机化
  - 在随机分配后，若协变量不平衡，则重复随机化直到满足预设平衡标准





常用的处理分配机制和统计推断方法

- Bernoulli Trial:
  - Z_i独立同分布，服从Bernoulli(r)
  - $n_1 = \sum_{i=1}^{n} Z_i$和$n_0 = \sum_{i=1}^{n}(1 - Z_i)$是随机的
- Completely Randomized Experiment（完全随机化试验）
  - 事先确定处理组和对照组数量，Z_i之间并不独立
  - $n_1 = \sum_{i=1}^{n} Z_i$和$n_0 = \sum_{i=1}^{n}(1 - Z_i)$固定

Meaning of No Treatment Effect

- No individual-level treatment effect
  - $\tau_i = E\{Y_i(1)\} - E\{Y_i(0)\} = 0$ for all i
- No population-level treatment effect (No average treatment effect)
  - $\tau = n^{-1} \sum_{i=1} \tau_i = 0$

Fisher随机化检验

- 基于Fisher Sharp Null $H_0: Y_i(1) = Y_i(0)$ (No individual-level effect)
- 1. 计算观测统计量$T^{obs} = \hat{\tau}$
- 2. 模拟所有随机分配
  - 2.1 在Sharp Null下， $Y_i(1) = Y_i(0) = Y_i$
  - 2.2 对任意的处理对照分配Z'都能计算对应的统计量$T(Z')$
- 3. 构造随机化分布
  - 重复所有的处理对照分配（或蒙特卡洛模拟），获得T的分布
- 4. 计算p-value
  - $p = P\left(|T(Z)| \geq \left|T^{obs}\right| \mid H_0 \right)$

Fisher随机化检验

- 优势：有限样本有效，不需要大样本或渐近正态性
- 劣势：
  - 1. 只能检验Sharp Null，无法检验平均因果效应为0
  - 2. 置信区间构造复杂
  - 3. 大样本下计算量大（需要重复所有的处理分配或蒙特卡洛模拟）

Fisher随机化检验：An Example

- 有4个学生参加一个教学实验
- Treatment：新教学方法
- 处理分配机制：2个分配到处理，2个分配到对照
- Observed outcome：

Student	1	2	3	4
Treatment	1	1	0	0
Score	80	85	70	75

- Test statistic：(80+85)/2-(70+75)/2=10

Fisher随机化检验：An Example

- Fisher Sharp Null下可以把未观测的结果进行填补

Student	1	2	3	4
$Y_i(1)$	80	85	70	75
$Y_i(0)$	80	85	70	75

- 按照原始处理分配机制重新分配处理对照：

Treated	1,2	1,3	1,4	2,3	2,4	3,4
Control	3,4	2,4	2,3	1,4	1,3	1,2
Test statistic	10	-5	0	0	5	-10

- p-value=1/3

Neyman随机化推断

- 基于$H_0: \tau = 0$
- 1. 计算检验统计量$\hat{\tau}$
- 2. 计算方差估计量$\hat{\sigma}^2$
- 3. 基于正态近似（中心极限定理）构造置信区间

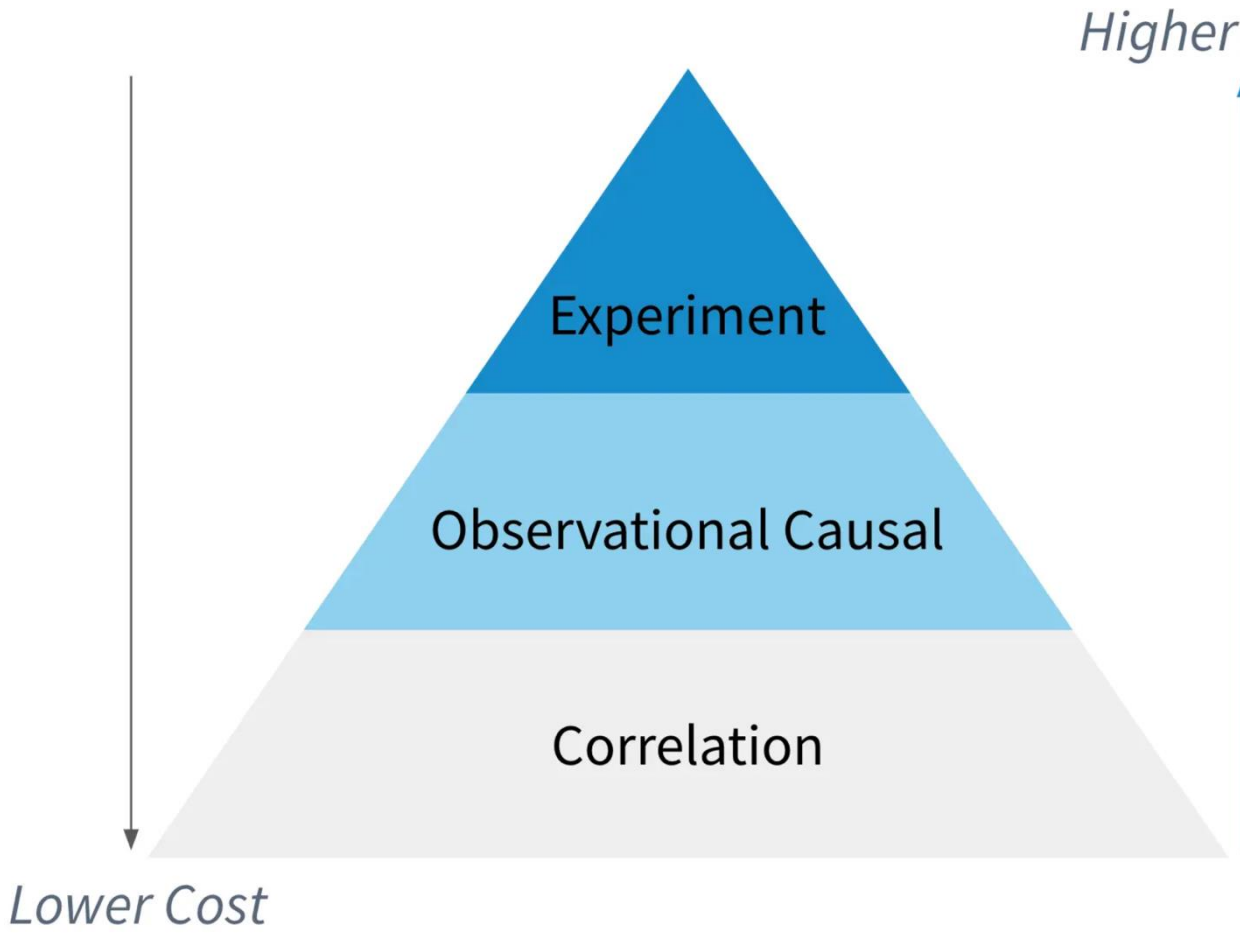
- 优势：关注的是$H_0: \tau = 0$，可以直接构造置信区间，易于加入协变量调整
- 劣势：不是有限样本精确推断，方差受到随机化机制影响

RCT的优势和局限

- 优势：因果识别清晰，偏差小，推断简单，金标准
- 局限：
  - 伦理限制：不能随机让人吸烟/不吸烟
  - 实际操作中不可行：环境暴露、社会政策

- 许多重要问题，如：吸烟对癌症、教育对收入、污染对健康、政策效果等问题的研究都无法做随机化
- 只能使用观察性数据时如何做因果推断？

随机化试验 vs 观察性研究



Randomized Experiment:
-Few assumptions
-Ground truth

Observational Causal Study:
-More assumptions
-Approximates experiment

Correlational Study:
-No causal claim

观察性研究

什么是观察性研究?

- 观察性研究才是生活的主要部分
- 特点:
  - 没有随机分配
  - 数据是自然产生的
- 例如:
  - 医疗记录
  - 经济数据
  - 社会调查
  - 平台数据
  - …

观察性研究的问题

- Confounder/Selection bias = treatment not randomized
- 两组个体可能本来就不同
- 例如：服药组 vs 未服药组
- 两组之间可能存在差异：
  - 病情严重程度：越严重越可能服药
  - 收入：收入越高越可能服药
  - 年龄：年龄越高越可能服药
  - 医疗条件：医疗条件越好越可能服药

观察性研究中的不可识别问题

- 在观察数据中：$Z_i \not\perp (Y_i(1), Y_i(0))$
- 使得因果效应不可直接识别
- 必须引入额外假设

- 直觉：是否能用观察性研究“模拟”随机化试验？
- 随机化试验：协变量相同时，接受处理分配的概率相同
- 常见识别假设：Unconfoundedness，$\big(Y_i(1), Y_i(0)\big) \perp Z_i \mid X$
  - 给定协变量后无混杂，即所有的混杂来自于给定的协变量

- 估计方法的本质都是在模拟随机化试验

观察性研究中的协变量平衡（Table 1）

- Table 1: Baseline characteristics table
  - 用于展示不同treatment group在协变量上的分布情况

Table 1: Characteristics across gender

Variables	Male(n=4915)	Female(n=5436)	Total(10351)	P−value
Weight (kg)	76.89 (68.61 − 85.62)	63.62 (56.25 − 73.60)	70.42 (60.67 − 81.19)	0.000
Body mass index (BMI)	25.15 (22.78−27.76)	24.42 (21.58 − 28.35)	24.82 (22.14 − 28.03)	0.587
Systolic blood pressure	130.00 (120.00 − 144.00)	124.00 (110.00 − 140.00)	128.00 (114.00 − 142.00)	0.000
Age group				0.750
20–29	1116 (10.78%)	1204 (11.63%)	2320 (22.41%)	
30–39	770 (7.44%)	852 (8.23%)	1622 (15.67%)	
40–49	610 (5.89%)	662 (6.40%)	1272 (12.29%)	
50–59	602 (5.82%)	689 (6.66%)	1291 (12.47%)	
60–69	1369 (13.23%)	1491 (14.40%)	2860 (27.63%)	
70+	448 (4.33%)	538 (5.20%)	986 (9.53%)	

P−values by t−test for continuous variables and Chi2 test for binary/categorical variables.

- source: https://asdocx.com/documentations/creating-and-working-with-asdocx-template-files/table1-template-for-baseline-characteristics-of-patients-asdocx/

Strategy 1: Matching

- 核心思想：寻找协变量相似的个体进行配对
  - 对每个处理组的个体，找到协变量相似的对照组个体
  - 对每个对照组的个体，找到协变量相似的处理组个体
- 从而可以直接获得因果效应的估计
- 优点：直观易理解
- 缺点：只能控制可观测协变量，协变量较高时很难找到合适匹配，需要定义何为“协变量相似”（如：欧氏距离）

Strategy 2: Outcome Regression

- 核心思想：直接建模$\hat{\mu}_z(X) \approx E(Y \mid Z = z, X)$
- ATE估计为$\hat{\tau} = n^{-1} \sum_{i=1}^{n} \{\hat{\mu}_1(X_i) - \hat{\mu}_0(X_i)\}$
- 常见形式：线性回归、逻辑回归、非参数回归等
- 优点：简洁直观
- 缺点：强模型依赖

Strategy 3: Propensity Score Method

- 核心思想：建模$P(Z=1 \mid X, Y(1), Y(0))$
- Propensity score（倾向性得分）：$e(X)=P(Z=1 \mid X, Y(1), Y(0))$
- Dimension reduction
  - 如果$(\mathrm{Y}(1), \mathrm{Y}(0)) \perp Z \mid X$，那么$(\mathrm{Y}(1), \mathrm{Y}(0)) \perp Z \mid e(X)$
- ATE under propensity score
  - Insight：$E\{Y_i(1)\}=E\left\{\frac{ZY}{e(X)}\right\}$，$E\{Y_i(0)\}=E\left\{\frac{(1-Z)Y}{1-e(X)}\right\}$
  - ATE：$\tau=E\{Y_i(1)-Y_i(0)\}=E\left\{\frac{ZY}{e(X)}-\frac{(1-Z)Y}{1-e(X)}\right\}$ (Homework：proof)

Strategy 3: Propensity Score Method

- Propensity score matching
  - 按每个个体的propensity score，匹配一个相似个体
  - ATE估计：matched treatment vs matched control
  - 优点：直观、类似随机试验
  - 缺点：丢数据
- Propensity score stratification
  - 按每个个体的propensity score分成若干个层
  - ATE估计：每层做平均，按层加权

Strategy 3: Propensity Score Method

- 最经典方法：Propensity score weighting
- ATE：$\tau = E\{Y_i(1) - Y_i(0)\} = E\left\{\frac{ZY}{e(X)} - \frac{(1-Z)Y}{1-e(X)}\right\}$
- ATE估计为$\hat{\tau} = \frac{1}{n}\sum_{i=1}^{n}\frac{Z_i Y_i}{\hat{e}(X_i)} - \frac{1}{n}\sum_{i=1}^{n}\frac{(1-Z_i)Y_i}{1-\hat{e}(X_i)}$
- 缺点：依赖于propensity score模型正确

Strategy 4: Double Robust

- 同时对outcome和propensity score进行建模

$$\hat{\tau} = \frac{1}{n}\sum_i \left[\hat{\mu}_1(X_i) - \hat{\mu}_0(X_i) + \frac{Z_i(Y_i - \hat{\mu}_1(X_i))}{\hat{e}(X_i)} - \frac{(1-Z_i)(Y_i - \hat{\mu}_0(X_i))}{1-\hat{e}(X_i)}\right]$$

- 理论保证：只需要二者中一个正确

- More modern: Double Machine Learning, Causal Forest, etc

Cohort Study（队列研究）

- 由因推果：按照暴露状态分组，随访结局
- 流程：对于一群暂时未发病的人，根据是否接触过某种危险因素（吸烟vs不吸烟）分成两组，然后随访一段时间，观察两组中新发病例的多少。
- 直觉：让我们看看吸烟的人以后会不会更容易得肺癌。

- 同时适用于前瞻性和回顾性研究
- Prospective Study（前瞻性研究）：研究开始时结局还未发生
- Retrospective Study（回顾性研究）：研究开始时结局已发生

Cohort Study（队列研究）

- 前瞻性队列研究：经典模式
  - 找一群尚未患病的人群，根据是否接触过某种因素分组，随访
  - 优点：数据质量高
  - 问题：需要等待、成本较高
  - 例：吸烟是否会增加肺癌死亡风险？招募40 701名男性，根据吸烟情况分组，随访50年

	肺癌死亡	未死于肺癌	合计
吸烟	305	34 134	34 439
不吸烟	10	6 252	6 262
合计	315	40 386	40 701

Cohort Study（队列研究）

- 回溯性队列研究
  - 对于已患病的人群，根据之前是否接触某种因素分组
  - 虽然在“查旧账”，但依旧遵循先看暴露再看结局的队列研究逻辑
  - 优点：省时省钱
  - 例：石棉暴露是否增加肺癌死亡风险？17 800名工人根据历史就业数据和死亡登记数据汇总下列表格

	肺癌死亡	未死于肺癌	合计
石棉暴露	89	7 911	8 000
无石棉暴露	22	9 778	9 800
合计	111	17 689	17 800

罕见病的队列研究

- Toy Example：研究某种暴露X是否会导致某种罕见病Y
- 问题：Y的发病率很低（如0.01%）
- 队列研究：招募100000个人，仅有10人发病；需要长期随访大量人群，成本极高，时间极长

- 如何解决？Case-Control Study
- 先找到病例（case），然后再找未患病对照（control）

Case-Control Study（病例对照研究）

- 由果溯因：按照患病状态分组，回溯暴露情况
- 流程：选取已经患病的人作为“病例组”（Case），选取未患病但背景相似的人作为“对照组”（Control）。然后回头调查他们过去的暴露史。
- 直觉：肺癌患者中，吸烟的比例是不是比健康人更高。

- 适用于罕见病的回顾性研究

- Weaker evidence than cohort studies

Cohort vs Case-Control Study: An Example

- Cohort Study: 按是否吸烟分组，然后随访是否发生肺癌

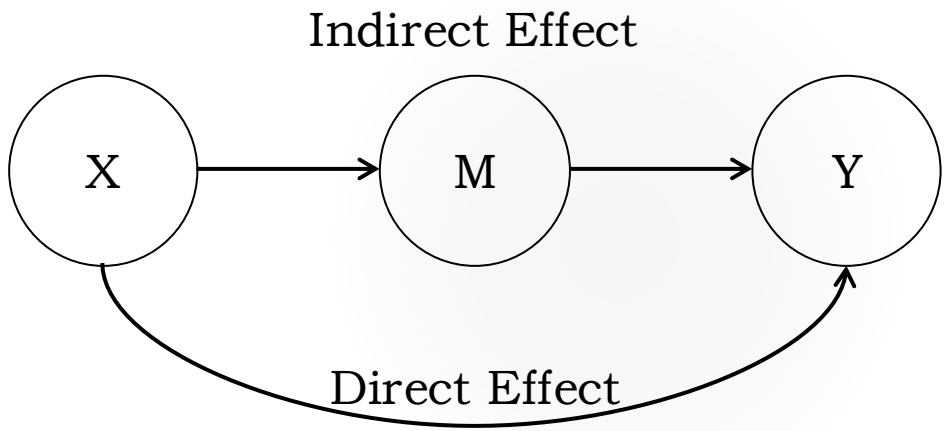
	肺癌	无肺癌	合计
吸烟	40	960	1000
不吸烟	10	2 990	3000

- Case-Control Study: 按是否患肺癌选人，然后回顾是否吸烟

	吸烟	不吸烟	合计
肺癌	80	20	100
无肺癌	60	40	100

Mediation Analysis（中介分析）

- 中介分析：X通过M影响结果Y
  - X：treatment/exposure
  - M：mediator（中介变量）
  - Y：outcome
- 例子：培训项目能否提高收入?
  - X（treatment）：是否参与培训项目
  - M（mediator）：是否习得了某项技能
  - Y（outcome）：收入是否提高



- Direct Effect：固定M，X对Y的效应
- Indirect Effect：X通过M对Y的效应

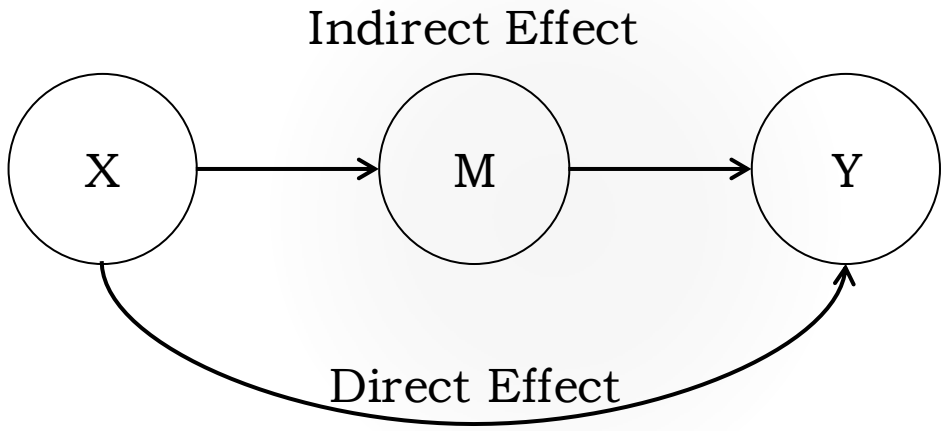
Mediation Analysis（中介分析）

Effect of X on the mediator M $M = \alpha_0 + \alpha_1 X + \varepsilon_M$

Effect of X and M on the outcome $Y = \beta_0 + \beta_1 X + \beta_2 M + \varepsilon_Y$

Effect identification

- β_1: direct effect of X on Y
- β_2: effect of mediator M on Y
- $\alpha_1\beta_2$: indirect effect of X on Y through the mediator M



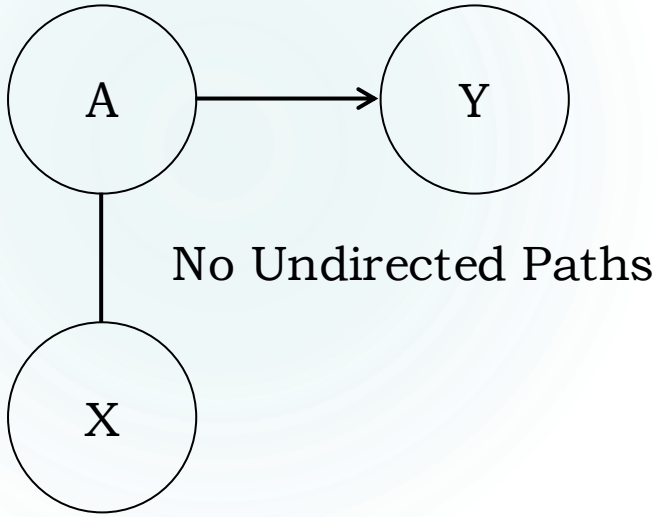
Directed Acyclic Graphs

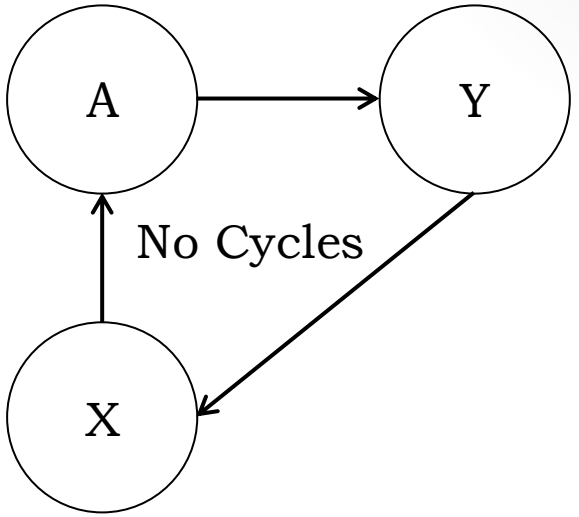
Directed Acyclic Graphs (DAGs) are graphical models used to represent causal relationships between variables.

Example: $A \to Y$, where A is the treatment and Y is the outcome. It indicates a causal link from A to Y.

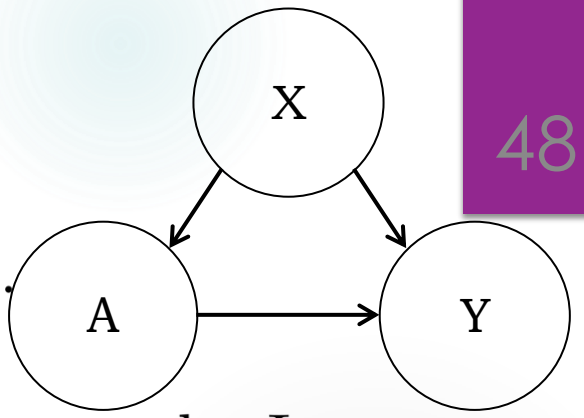
Definition of DAGs: *Directed* graphs with *no cycles*.

These are not DAGs:





DAGs and Confounding



There are two paths from treatment A to outcome Y.

Frontdoor path The path $A \to Y$ is called a frontdoor path. It represents effect of the treatment.

Backdoor path The path $A \leftarrow X \to Y$ from A to Y is a backdoor path. Nodes on a backdoor path are typically **confounders**. Therefore, X is a confounder, which causes both A and Y. Backdoor paths need to be **blocked**.

Blocking paths (The backdoor path criterion) Blocking **all** backdoor paths from treatment A to outcome Y is sufficient to control for confounding.

It can be done by **controlling** for some variables: stratification by it, adjusting for it in a regression, or matching on it, etc.

Three Key Elements in DAGs

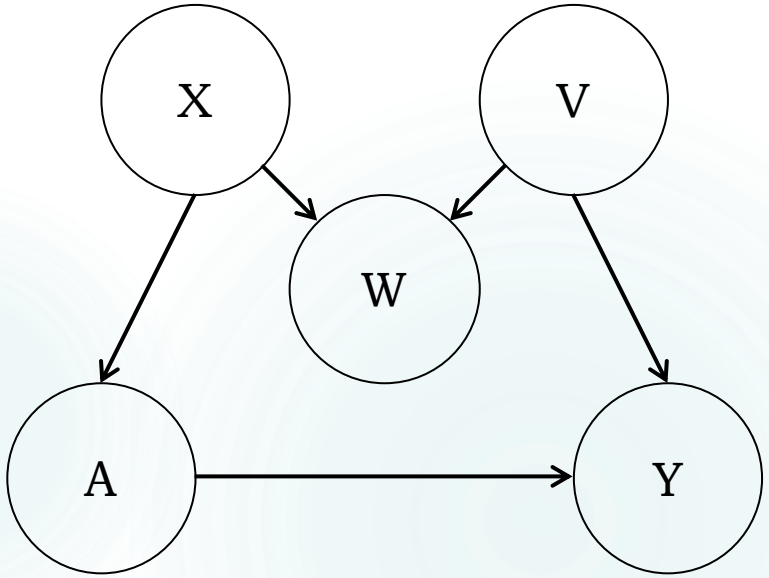
There are three key elements in DAGs.

Chain $X \to Y \to Z$ (mediator). It means X and Z are independent conditioning on Y. To block the path, we need control for Y.

Fork $X \leftarrow Y \to Z$ (confounder). It means X and Z are independent conditioning on Y. To block the path, we need control for Y.

Collider $X \to Y \leftarrow Z$. It means X and Z are marginally independent, but *conditionally dependent* given Y. To block the path, we *should not* control for Y.

Three Key Elements in DAGs: An Example



The backdoor path from treatment to outcome: $A \leftarrow X \rightarrow W \leftarrow V \rightarrow Y$.

Note that W is a **collider** on this path, so there is no unblocked backdoor path from A to Y.

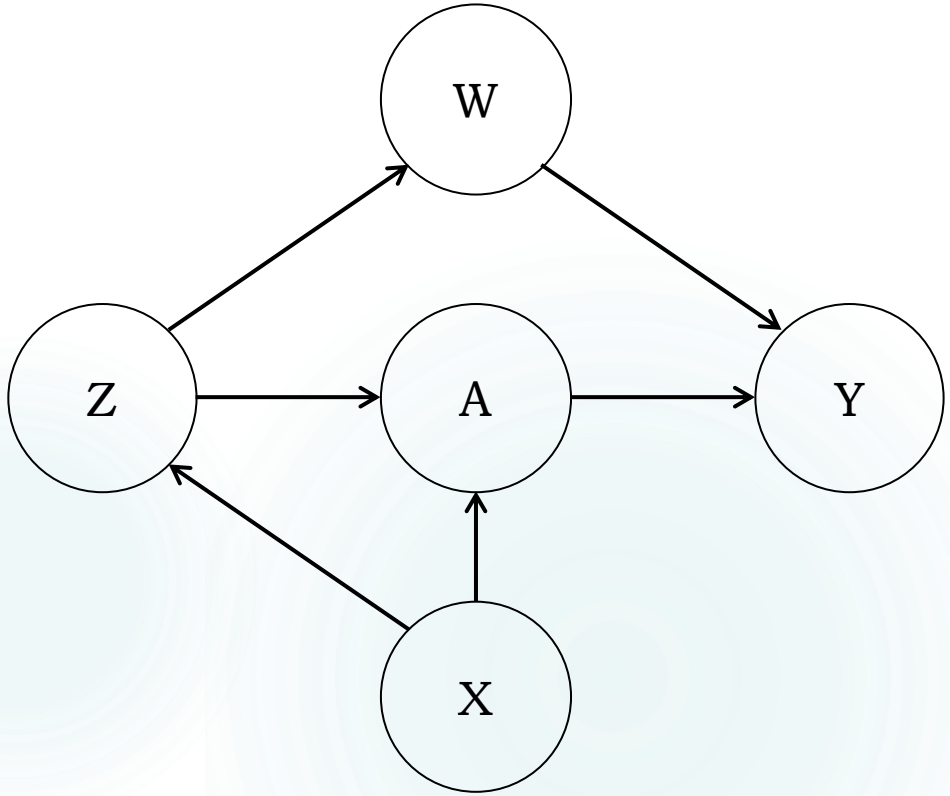
By the backdoor path criterion, we don't need to control for anything.

Confounder selection based on DAGs

Sets of variables sufficient to control for confounding between A and Y:

$$\varnothing, \{X\}, \{V\}, \{X, W\}, \{W, V\}, \{X, V\}, \{X, W, V\}.$$

Confounder selection based on DAGs



Backdoors $A \leftarrow X \rightarrow Z \rightarrow W \rightarrow Y$ and $A \leftarrow Z \rightarrow W \rightarrow Y$

Confounder selection based on DAGs Sets of variables sufficient to control for confounding between A and Y:

$$\{Z\}, \{W\}, \{Z, W\}, \{X, W\}, \{X, Z\}, \{X, Z, W\}.$$