Final Project

生物统计和生物信息引论

2026 年 4 月 30 日

1 作业目标

本课程大作业旨在训练学生基于可公开获取的真实数据，围绕一个明确的科学或医学问题，完成从数据获取、预处理、方法应用到结果解释的完整分析流程。原则上要求使用公开可获取的数据集，即无需长期审批、无需付费购买、可以自行合法获取的数据资源。不建议使用受限访问、申请周期较长或仅少数人可获取的数据。

2 选题原则

1. 选题应围绕一个明确的研究问题展开，而非单纯展示数据、拟合模型或比较模型效果。
2. 研究问题应具有医学、生物学或公共健康背景。
3. 允许使用 AI 工具作为辅助，但不得使用 AI 替代理解、核查以及判断。
4. 鼓励使用医学临床数据、遗传/组学数据、单细胞测序数据、蛋白结构数据、生理信号或医学时间序列数据。
5. 鼓励学生自选公开数据集完成项目。课程将提供若干可选数据源和研究方向作为参考，但这些方向相对有限，学生可以基于课程提供的方向做进一步扩展。无论是否使用课程提供的数据，都需在报告中清楚说明数据来源。

3 完成方式

大作业以小组形式完成，每组 1–3 人。作业成绩以小组为单位评定，并在评分时考虑小组人数差异。

4 时间安排

- 4 月 30 日：完成组队；发布更详细的大作业说明（包括推荐研究方向与可选数据源等）
- 5 月 17 日：提交开题报告（包括研究问题、数据来源、拟采用方法及预期结果等）
- 6 月 9 日：课程展示（约 10–15 分钟，具体时长视分组数量而定）

5 可选方向与示例数据源

5.1 已有研究论文复现

可选择一篇发表于高影响力期刊的研究论文，进行核心结果复现，并在此基础上完成一项方法或数据层面的扩展分析。所选论文应满足以下条件：

- 与课程主题相关（因果推断、生存分析、单细胞、遗传、蛋白质、医学数据等）；明确论文的研究问题、数据来源、核心方法与主要结论，用自己的语言重构其分析逻辑（而非简单摘要）；结果对比与误差分析。
- 若原论文包含机器学习或深度学习模型，原则上应重新训练或重新拟合核心模型，不得仅直接调用作者提供的最终权重或结果文件。若原论文使用传统统计模型、因果推断方法或生存分析方法，则应重新完成数据预处理、模型拟合、估计和结果验证。
- 请尽量选择在自己计算资源范围内的论文。若因计算资源限制无法完整复现，应说明简化方案及其对结论的影响。
- 必须明确回答：
  - 用了什么统计方法，原理是什么
  - 哪些结果成功复现
  - 哪些结果未成功复现
  - 差异可能来自哪里（数据版本、参数、预处理、随机性）
  - 方法的局限性
- 需要讨论：
  - 原论文方法的关键假设
  - 这些假设在你的复现中是否成立
  - 原论文可能存在的局限或者偏倚

5.2 因果推断

- 公开数据源：
  - National Center for Health Statistics（NCHS）发布的公开健康统计数据，数据来源为 NCHS 官方网站：https://www.cdc.gov/nchs/.
- 可选研究问题示例：
  - 吸烟、睡眠、饮食、运动等生活方式因素对慢病风险的影响；
  - 某种治疗或干预对患者预后的影响；
  - 社会经济因素对健康结局的影响；
  - 不同人群之间 treatment effect heterogeneity（异质性治疗效应）的探索。

5.3 生存分析

- 公开数据源：
  - National Center for Health Statistics（NCHS）发布的公开健康统计数据，数据来源为 NCHS 官方网站：https://www.cdc.gov/nchs/.
  - TrialBench：https://www.nature.com/articles/s41597-025-05680-8.
  - TrialPanorama: https://huggingface.co/datasets/TrialPanorama/TrialPanorama-dat
- 可选研究问题示例：
  - 某项生活方式因素对全因死亡风险的影响；
  - 某类患者的生存时间预测；
  - 不同治疗方案之间的生存差异；
  - 癌症患者不同亚组之间的预后比较。

5.4 遗传与基因组数据分析

- 公开数据集：1000 Genomes https://www.internationalgenome.org/data/；GWAS Catalog https://www.ebi.ac.uk/gwas/； ClinVar https://www.ncbi.nlm.nih.gov/clinvar/等
- 可选研究问题示例
  - 基于 1000 Genomes 数据，分析不同大陆人群的遗传结构；并比较若干疾病相关 SNP 的群体频率差异，基于 GWAS Catalog，整理两种疾病之间显著关联位点，分析二者是否共享遗传风险基因。

5.5 蛋白质序列、结构与功能数据分析

- 可使用公开蛋白质序列、注释、结构或预测结构数据，围绕蛋白功能、结构域、突变影响、蛋白家族比较或结构–功能关系展开分析。推荐数据源包括：UniProt(https://www.uniprot.org/)，可获取蛋白质序列、功能注释、结构域、亚细胞定位、变体和 GO 注释等信息；RCSB Protein Data Bank / PDB(https://www.rcsb.org/)，可获取实验测定的蛋白质、核酸和复合物三维结构，并支持结构检索、可视化和批量下载；AlphaFold Protein Structure Database(https://alphafold.ebi.ac.uk/)，由 EMBL-EBI 与 Google DeepMind 合作维护，提供大规模蛋白质结构预测结果，可用于缺少实验结构的蛋白分析。
  - 同一家族蛋白的序列保守区域是否对应特定功能结构域或活性位点？
  - AlphaFold 预测结构与 PDB 实验结构之间是否存在差异？这些差异集中在哪些区域？
  - 蛋白质的结构特征，例如二级结构比例、表面暴露残基、结构域数量，是否与功能类别相关？

5.6 其他数据方向

- 临床试验数据集:
  - TrialBench：https://www.nature.com/articles/s41597-025-05680-8.
  - TrialPanorama: https://huggingface.co/datasets/TrialPanorama/TrialPanorama-dat
- 单细胞测序数据
- 生理信号或医学时间序列数据 (血糖浓度，脑电信号)

6 AI 工具使用说明

本作业允许使用 AI 工具辅助完成项目，但须遵守以下规则：

1. 可以使用 AI 辅助：
   - 阅读数据文档、生成代码框架、调试程序、优化图表表达、梳理报告结构。
2. 不可以使用 AI：
   - 伪造数据、结果、文献或结论；
   - 代替你理解方法和核查结果；

- 直接生成整份报告后不加核验地提交。

3. 你需要在提交材料中简单说明：

   - 使用了哪些 AI 工具，用在了什么环节，你如何核查其输出的正确性。

所有最终结果由学生本人负责。

7 提交材料

请提交以下内容：

1. 开题报告 1 份，建议长度不超过 4 页，包括数据来源、数据的预处理与简单描述、拟探究的科学问题、拟采用的研究方法。提交日期：5 月 17 日。
2. 项目展示 PPT，展示时间为 6 月 9 日，展示时长约 10–15 分钟，具体时长视分组数量而定，会另行通知。
3. 项目报告 1 份，建议长度约 4–8 页，主要内容包括数据来源、研究问题、研究方法、研究结果、研究结论与局限性。提交日期：6 月 16 日。
4. 项目报告的附录 1 份，随项目报告上交，可包括以下内容：

   - README：简要介绍附录里面各个文件的内容和作用。
   - 代码或 NOTEBOOK：要求可读、可运行，并在内部加上解释说明。
   - AI 使用说明。
   - 其他你认为项目报告中没有体现的内容。